

AIFAKER

PGD 기반 적대적 노이즈를 활용한 딥페이크 방지 필터

1. 소개


개요

코드 깃허브

웹페이지

프레젠테이션

시연 자료 링크



2. 연구 배경 및 필요성

딥페이크 범죄 사례

연말뉴스
자인 얼굴·SNS 사진 합성 '딥페이크' 음란을 전국서
가습

Google 딥페이크

딥페이크 성착취물로 청소년 합작시 3년형... 4월에 달라지는 반형

딥페이크 사진 합성... SNS에 올린 사진이 딥페이크로 합성된 것으로 밝혀졌다. SNS에 올린 사진이 딥페이크로 합성된 것으로 밝혀졌다. SNS에 올린 사진이 딥페이크로 합성된 것으로 밝혀졌다.

딥페이크 상반화: 끝나지 않은 피해자들의 싸움

딥페이크는 장난 아닌 인격 침해 중범죄



딥페이크만 검색하더라도 관련 범죄에 대해 뉴스가 많다. -> 딥페이크를 방지하는 방법이 있을까?

여기에 대한 해결책을 중심으로 연구를 시작하였고 딥페이크 관련 공개된 자료와 그에 대응하는 모델을 연구하게 되었다. 비즈니스 모델을 적용하여 눈으로 탐지하기 어렵지만 딥페이크 학습을 방해하는 모델을 웹서비스로 구현하는 것을 목표로 하였다.

3. 이론 배경


딥페이크 및 StarGANv2

- GAN(생성적 적대 신경망)을 기반으로 한 이미지 변환 모델



PGD (적대적 노이즈 기법)

- PGD의 정의
 - PGD(Projected Gradient Descent)는 적대적 공격 기법으로, 입력 이미지에 작은 노이즈를 반복적으로 추가하여 모델을 속이거나 성능을 저하시키는 방법
 - 경사 하강법을 사용하며, 교란 크기를 epsilon 범위로 제한
- PGD 모델의 작동 방식
 - 초기 노이즈 추가 후, 손실 함수의 경사를 계산
 - 경사 방향으로 교란을 업데이트하고, epsilon 내로 투영
 - 지정된 반복 횟수(num_iter) 동안 최적화



4. 필터 구현 및 결과

PGD 적용 Before/After

Before

After

- Before: 적대적 노이즈 적용 전
- After: 적대적 노이즈 적용 후 결과


이미지에 미세한 조정을 하여 사람 눈으로 차이를 바로 알아보기 어렵다.

StarGANv2 딥페이크 테스트 결과

합성사진	필터 적용 전	필터 적용 후	Deepfake 성공	Deepfake 실패

5. 웹 애플리케이션


전체 아키텍처



SNS/블로그 흐름도



6. 프로젝트 일정 및 개발 흐름




7. 웹 백엔드 구성

핵심 기술 스택


Flask 기반 웹 애플리케이션 + 노이즈 모델 + 프론트엔드 통합 프로젝트

GitHub Actions를 활용한 CI/CD와 Azure 배포까지 전 과정 포함

CI/CD 파이프라인



데이터베이스 아키텍처



8. 한계점 및 향후 개선 방향

- 공개된 딥페이크가 정보가 부족해서 딥페이크의 다양한 모델에 대한 테스트를 진행하지 못함
- 모델들의 연구를 더 진행하여 추가 필터 적용
- PGD 기반을 활용해 StarGANv2 딥페이크를 방해하는 필터를 완성하였으나 웹서버에 V2 사전학습 데이터는 이식하지 못함 (현재 웹서버에 적용된 필터는 프로토 타입 모델)
- 사전학습 데이터를 웹 서버에 추가하여 더 자연스러운 필터를 구현할 예정