

AIFAKER

PGD 기반 적대적 노이즈를 활용한 딥페이크 방지 필터

1. 소개


개요

코드 깃허브

웹페이지

프레젠테이션

시연 자료 링크



2. 연구 배경 및 필요성

딥페이크 범죄 사례



딥페이크만 검색하더라도 관련 범죄에 대해 뉴스가 많다. -> 딥페이크를 방지하는 방법이 없을까?


여기에 대한 해결책을 중심으로 연구를 시작하였고 딥페이크 관련 공개된 자료와 그에 대응하는 모델을 연구하게 되었다. 비즈니스 모델을 적용하여 눈으로 탐지하기 어렵지만 딥페이크 학습을 방해하는 모델을 웹서비스로 구현하는 것을 목표로 하였다.

3. 이론 배경

딥페이크 및 StarGANv2


- GAN(생성적 적대 신경망)을 기반으로 한 이미지 변환 모델

$$\min_D \max_G V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log (1 - D(G(z)))].$$



- StarGAN v2의 핵심 기능은 다중 도메인 이미지 변환 ex) 사람 얼굴을 "금발 여성 스타일", "고양이 얼굴 스타일" 등으로 바꾸는 작업.
- 기본 GAN은 단순히 진짜 이미지를 만드는 데 초점이 맞춰져 있다면, StarGAN 시리즈는 이미지 간 변환에 특화

- StarGAN v2작동방식



- StarGANv2를 딥페이크에 사용하는 이유

- 얼굴 스타일을 자유롭게 바꿀 수 있어서 딥페이크 제작에 활용됨
- 최신 이미지 변환 모델 중 하나라, 딥페이크 방지 기술을 테스트하기에 적합한 강력한 상태
- 다양한 스타일을 다룰 수 있고, 결과가 자연스러워서 실제 딥페이크 시나리오를 시뮬레이션하기 좋음

PGD (적대적 노이즈 기법)


- PGD의 정의

-PGD(Projected Gradient Descent)는 적대적 공격 기법으로, 입력 이미지에 작은 노이즈를 반복적으로 추가하여 모델을 속이거나 성능을 저하시키는 방법

- 경사 하강법을 사용하며, 교란 크기를 epsilon 범위로 제한

- PGD 모델의 작동 방식

- 초기 노이즈 추가 후, 손실 함수의 경사를 계산
- 경사 방향으로 교란을 업데이트하고, epsilon 내로 투영
- 지정된 반복 횟수(num_iter) 동안 최적화



- PGD의 장점

- 강력함: 단일 단계 공격보다 효과적인 교란 생성
- 조정 가능: epsilon, alpha로 교란 강도 제어
- 유연성: LPIPS, MSE 등 다양한 손실 함수 결합 가능
- 안정성: 반복적 최적화로 신뢰할 수 있는 결과 제공

- 딥페이크 대응 모델로 PGD를 선택한 이유

-FGSM같은 단일단계공격보다 더 정교한 반복적 접근법 사용. 여러 번에 걸쳐서 노이즈를 조금씩 조정하면서 모델이 인식하지 못할 정도로 미세하지만, 최대한 효과적인 방향으로 데이터를 변형

- PGD는 수학적으로 안정적이고 이론적 기반이 탄탄

4. 필터 구현 및 결과


PGD 적용 Before/After



- Before: 적대적 노이즈 적용 전
- After: 적대적 노이즈 적용 후 결과


이미지에 미세한 조정을 하여 사람 눈으로 차이를 바로 알아보기 어렵다.

StarGANv2 딥페이크 테스트 결과




5. 웹 애플리케이션


전체 아키텍처



SNS/블로그 사용자 흐름도



6. 프로젝트 일정 및 개발 흐름




7. 웹 백엔드 구성

핵심 기술 스택


Flask 기반 웹 애플리케이션 + 노이즈 모델 + 프론트엔드 통합 프로젝트

GitHub Actions를 활용한 CI/CD와 Azure 배포까지 전 과정 포함

CI/CD 파이프라인



데이터베이스 아키텍처



8. 한계점 및 향후 개선 방향

- 공개된 딥페이크 데이터가 부족해서 딥페이크의 다양한 모델에 대한 테스트를 진행하지 못함

모델들의 연구를 더 진행하여 추가 필터 적용 예정

- PGD 기반을 활용해 StarGANv2 딥페이크를 방해하는 필터를 완성하였으나 웹서비스에 V2 사전학습 데이터는 이식하지 못함 (현재 웹서비스에 적용된 필터는 프로토타입 모델)

사전학습 데이터를 웹 서버에 추가하여 더 자연스러운 필터를 구현할 예정