AIFAKER

PGD 기반 적대적 노이즈를 활용한 딥페이크 방지 필터

1. 소개

개요

코드 깃허브

웹페이지

프레젠테이션

2. 연구 배경 및 필요성

딥페이크 범죄 사례

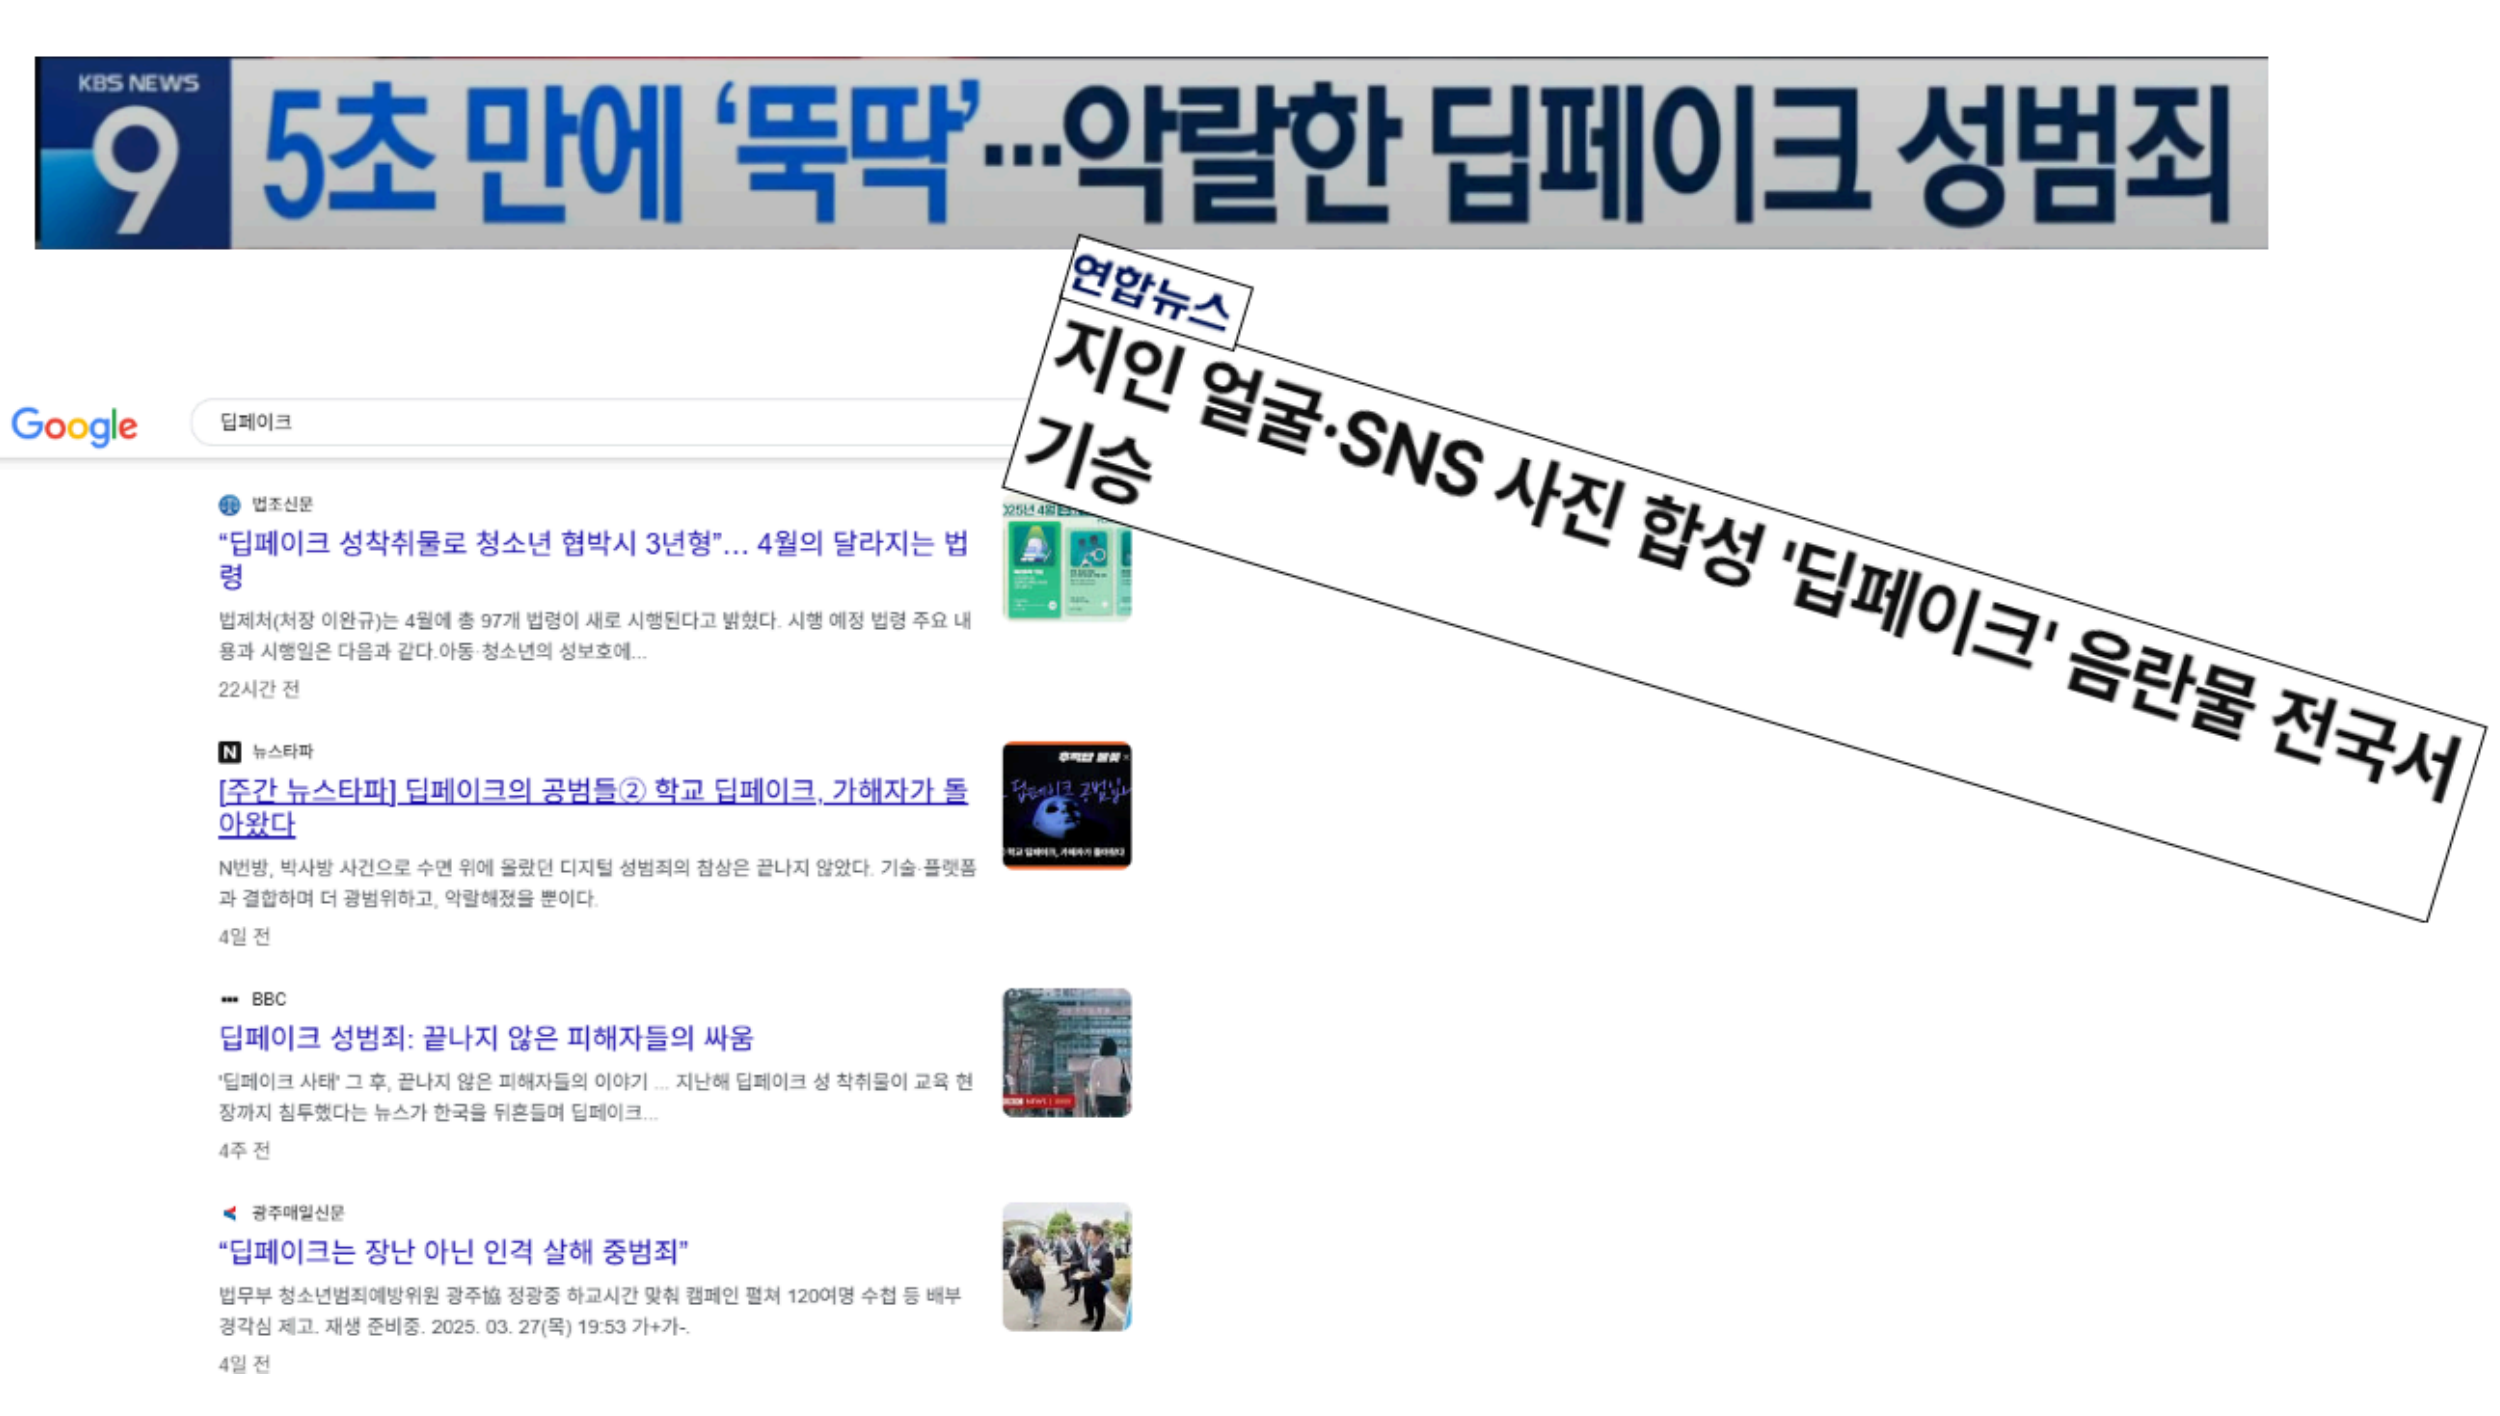
KBS NEWS 9
5초 만에 '뚝딱'…악랄한 딥페이크 성범죄
연합뉴스
지인 얼굴·SNS 사진 합성 '딥페이크' 음란물 전국서 기승
Google
딥페이크

법조신문

"딥페이크 성착취물로 청소년 협박시 3년형"… 4월의 달라지는 법령

법제처(처장 이완규)는 4월에 총 97개 법령이 새로 시행된다고 밝혔다. 시행 예정 법령 주요 내용과 시행일은 다음과 같다.아동·청소년의 성보호에...

22시간 전

뉴스타파

[주간 뉴스타파] 딥페이크의 공범들② 학교 딥페이크, 가해자가 돌아왔다

N번방, 박사방 사건으로 수면 위에 올랐던 디지털 성범죄의 참상은 끝나지 않았다. 기술·플랫폼과 결합하며 더 광범위하고, 악랄해졌을 뿐이다.

4일 전

BBC

딥페이크 성범죄: 끝나지 않은 피해자들의 싸움

'딥페이크 사태' 그 후, 끝나지 않은 피해자들의 이야기 ... 지난해 딥페이크 성 착취물이 교육 현장까지 침투했다는 뉴스가 한국을 뒤흔들며 딥페이크...

4주 전

광주매일신문

"딥페이크는 장난 아닌 인격 살해 중범죄"

법무부 청소년범죄예방위원 광주協 정광중 하교시간 맞춰 캠페인 펼쳐 120여명 수첩 등 배부 경각심 제고. 재생 준비중. 2025. 03. 27(목) 19:53 가+가-.

4일 전

딥페이크만 검색하더라도 관련 범죄에 대해 뉴스가 많다. -> 딥페이크를 방지하는 방법이 없을까?

여기에 대한 해결책을 중심으로 연구를 시작하였고 딥페이크 관련 공개된 자료와 그에 대응하는 모델을 연구하게 되었다.

비즈니스 모델을 적용하여 눈으로 탐지하기 어렵지만 딥페이크 학습을 방해하는 모델을 웹서비스로 구현하는 것을 목표로 하였다.

3. 이론 배경

딥페이크 및 StarGANv2

- GAN(생성적 적대 신경망)을 기반으로 한 이미지 변환 모델

$$\min_G \max_D V(D,G) = \mathbb{E}_{x\sim p_{data}(x)}[\log D(x)] + \mathbb{E}_{z\sim p_z(z)}[\log(1 - D(G(z)))].$$

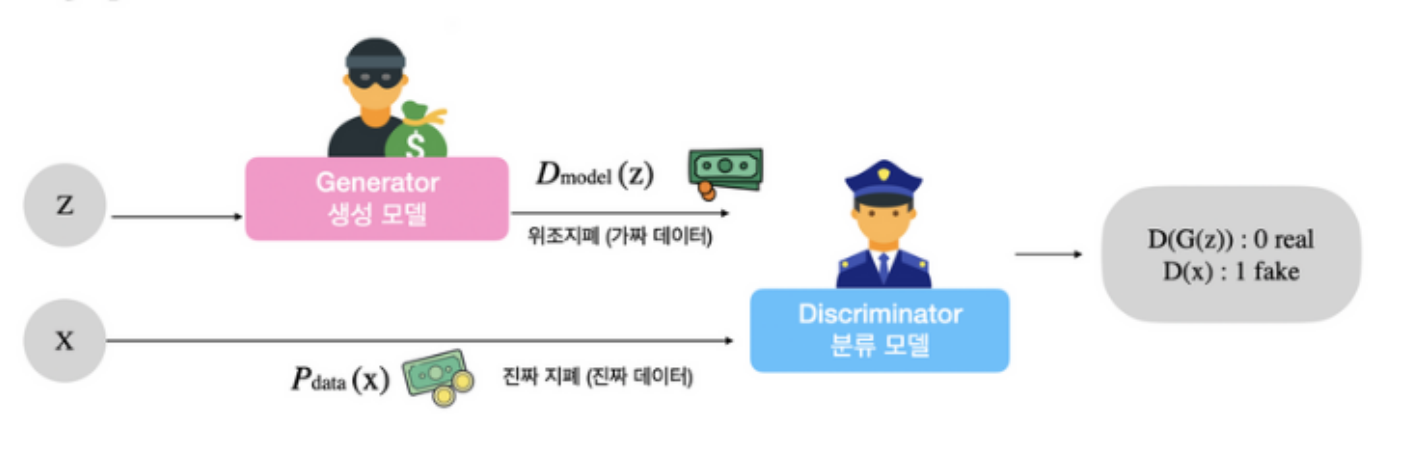
Z
X
Generator
생성 모델
Dmodel (Z)
위조지폐 (가짜 데이터)
Pdata (X)
진짜 지폐 (진짜 데이터)
Discriminator
분류 모델
D(G(z)) : 0 real
D(x) : 1 fake

  - StarGAN v2의 핵심 기능은 다중 도메인 이미지 변환 ex) 사람 얼굴을 "금발 여성 스타일", "고양이 얼굴 스타일" 등으로 바꾸는 작업.
  - 기본 GAN은 단순히 가짜 이미지를 만드는 데 초점이 맞춰져 있다면, StarGAN 시리즈는 이미지 간 변환에 특화
- StarGAN v2작동방식

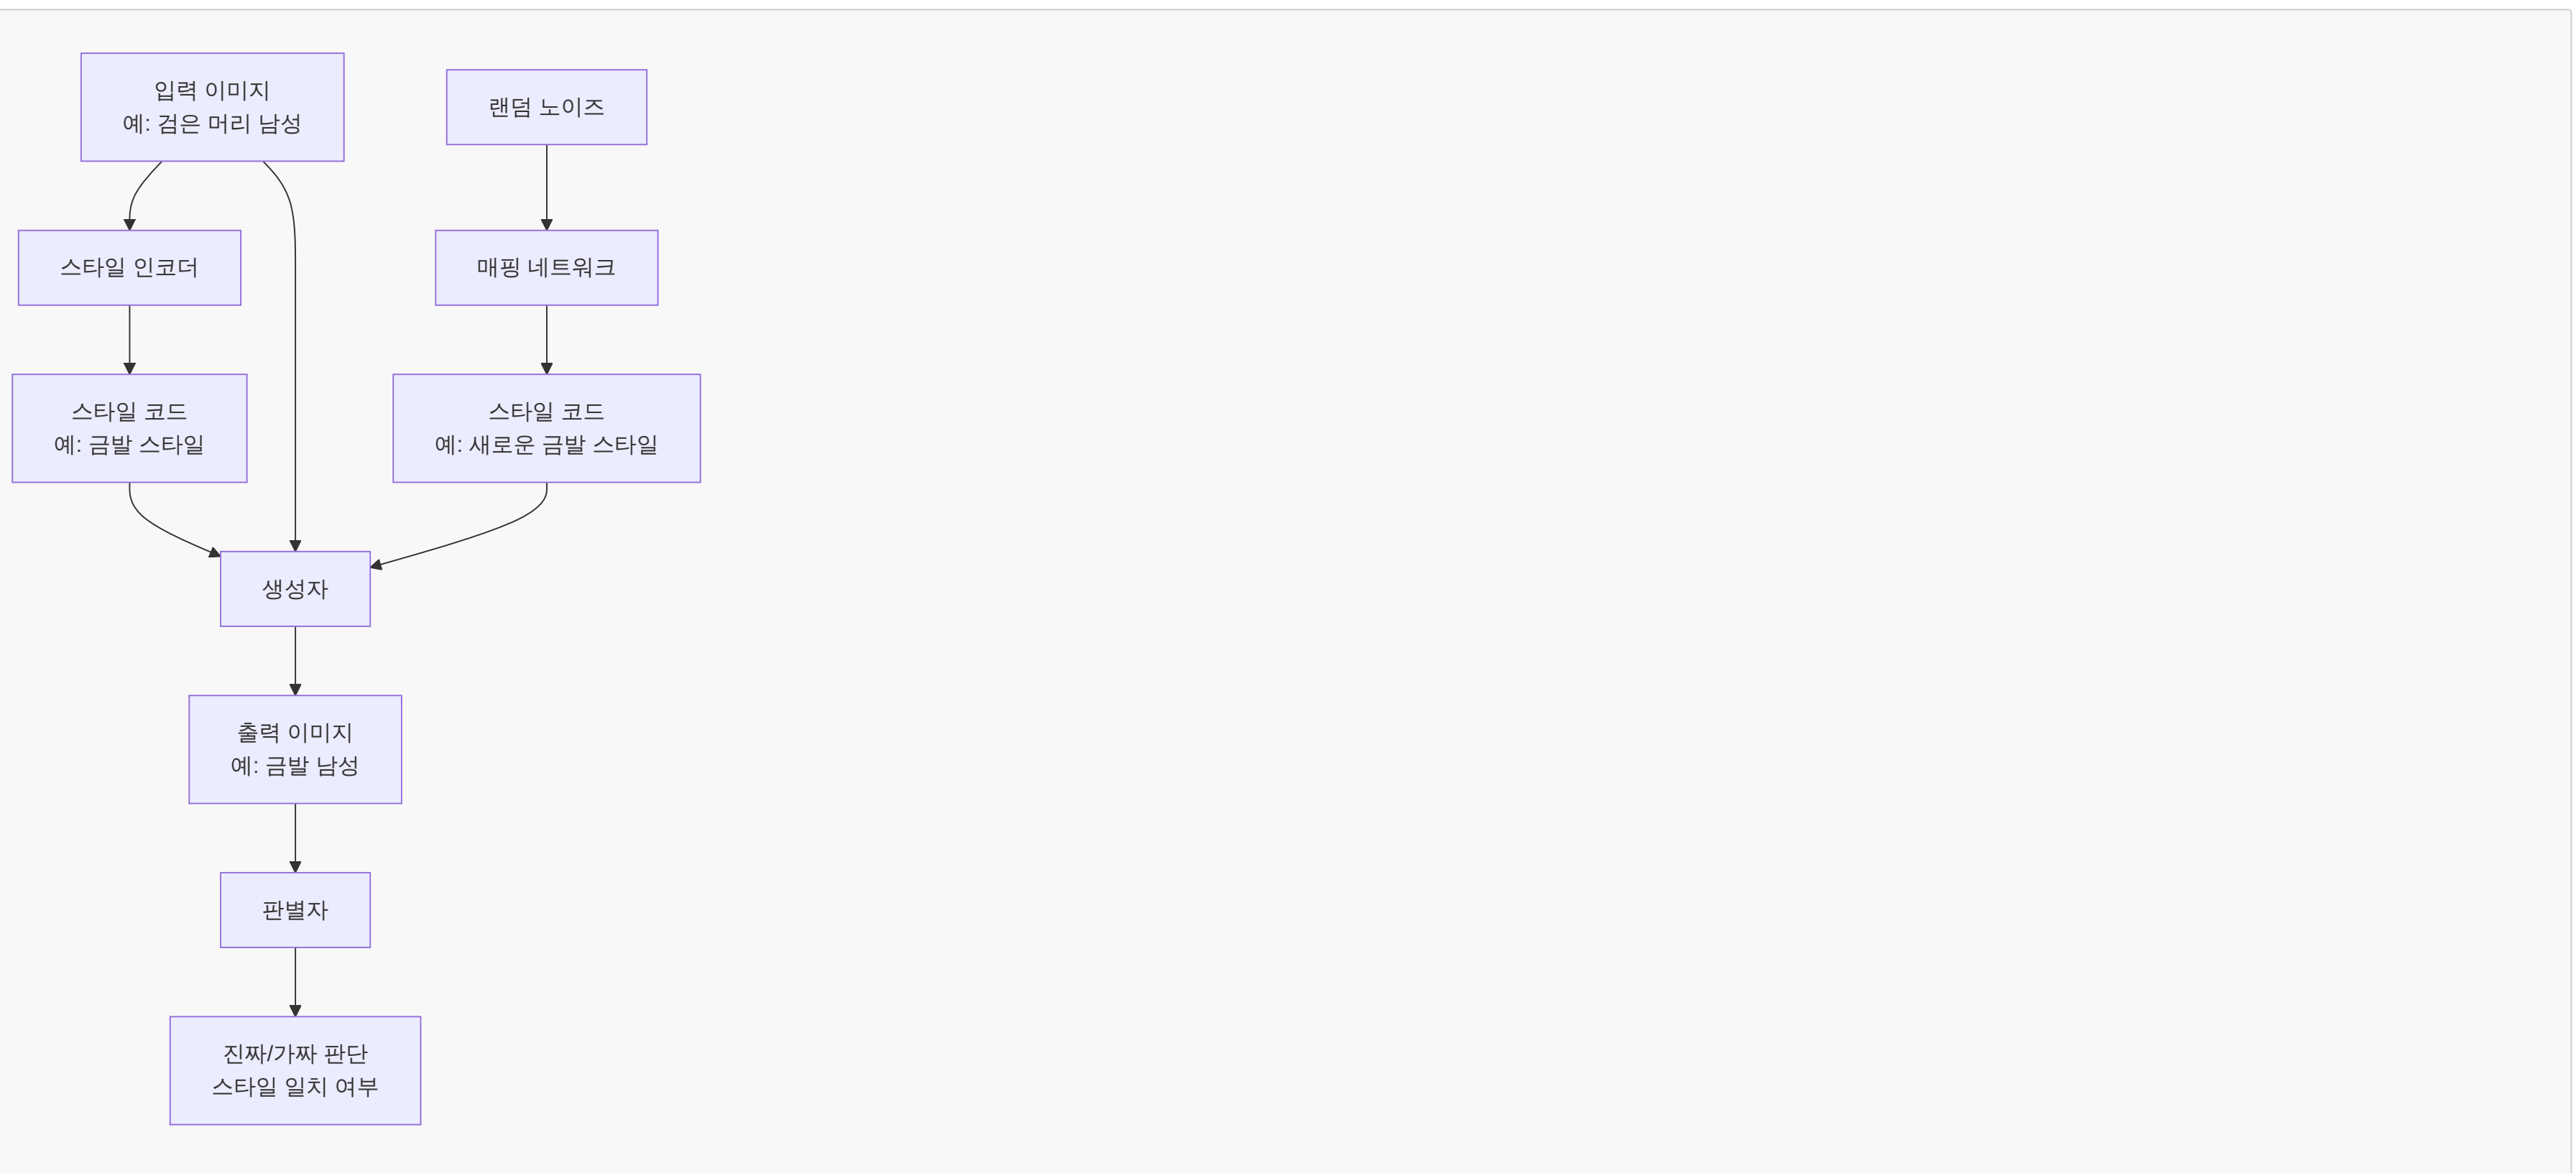
입력 이미지
예: 검은 머리 남성
랜덤 노이즈
스타일 인코더
매핑 네트워크
스타일 코드
예: 금발 스타일
스타일 코드
예: 새로운 금발 스타일
생성자
출력 이미지
예: 금발 남성
판별자
진짜/가짜 판단
스타일 일치 여부

  - **StarGANv2를 딥페이크에 사용하는 이유**

    -얼굴 스타일을 자유롭게 바꿀 수 있어서 딥페이크 제작에 활용됨

    -최신 이미지 변환 모델 중 하나라, 딥페이크 방지 기술을 테스트하기에 적합한 강력한 상대

    -다양한 스타일을 다룰 수 있고, 결과가 자연스러워서 실제 딥페이크 시나리오를 시뮬레이션하기 좋음

PGD (적대적 노이즈 기법)

- PGD의 정의

  -PGD(Projected Gradient Descent)는 적대적 공격 기법으로, 입력 이미지에 작은 노이즈를 반복적으로 추가하여 모델을 속이거나 성능을 저하시키는 방법

  -경사 하강법을 사용하며, 교란 크기를 epsilon 범위로 제한

- PGD 모델의 작동 방식

  -초기 노이즈 추가 후, 손실 함수의 경사를 계산

  -경사 방향으로 교란을 업데이트하고, epsilon 내로 투영

  -지정된 반복 횟수(num_iter) 동안 최적화

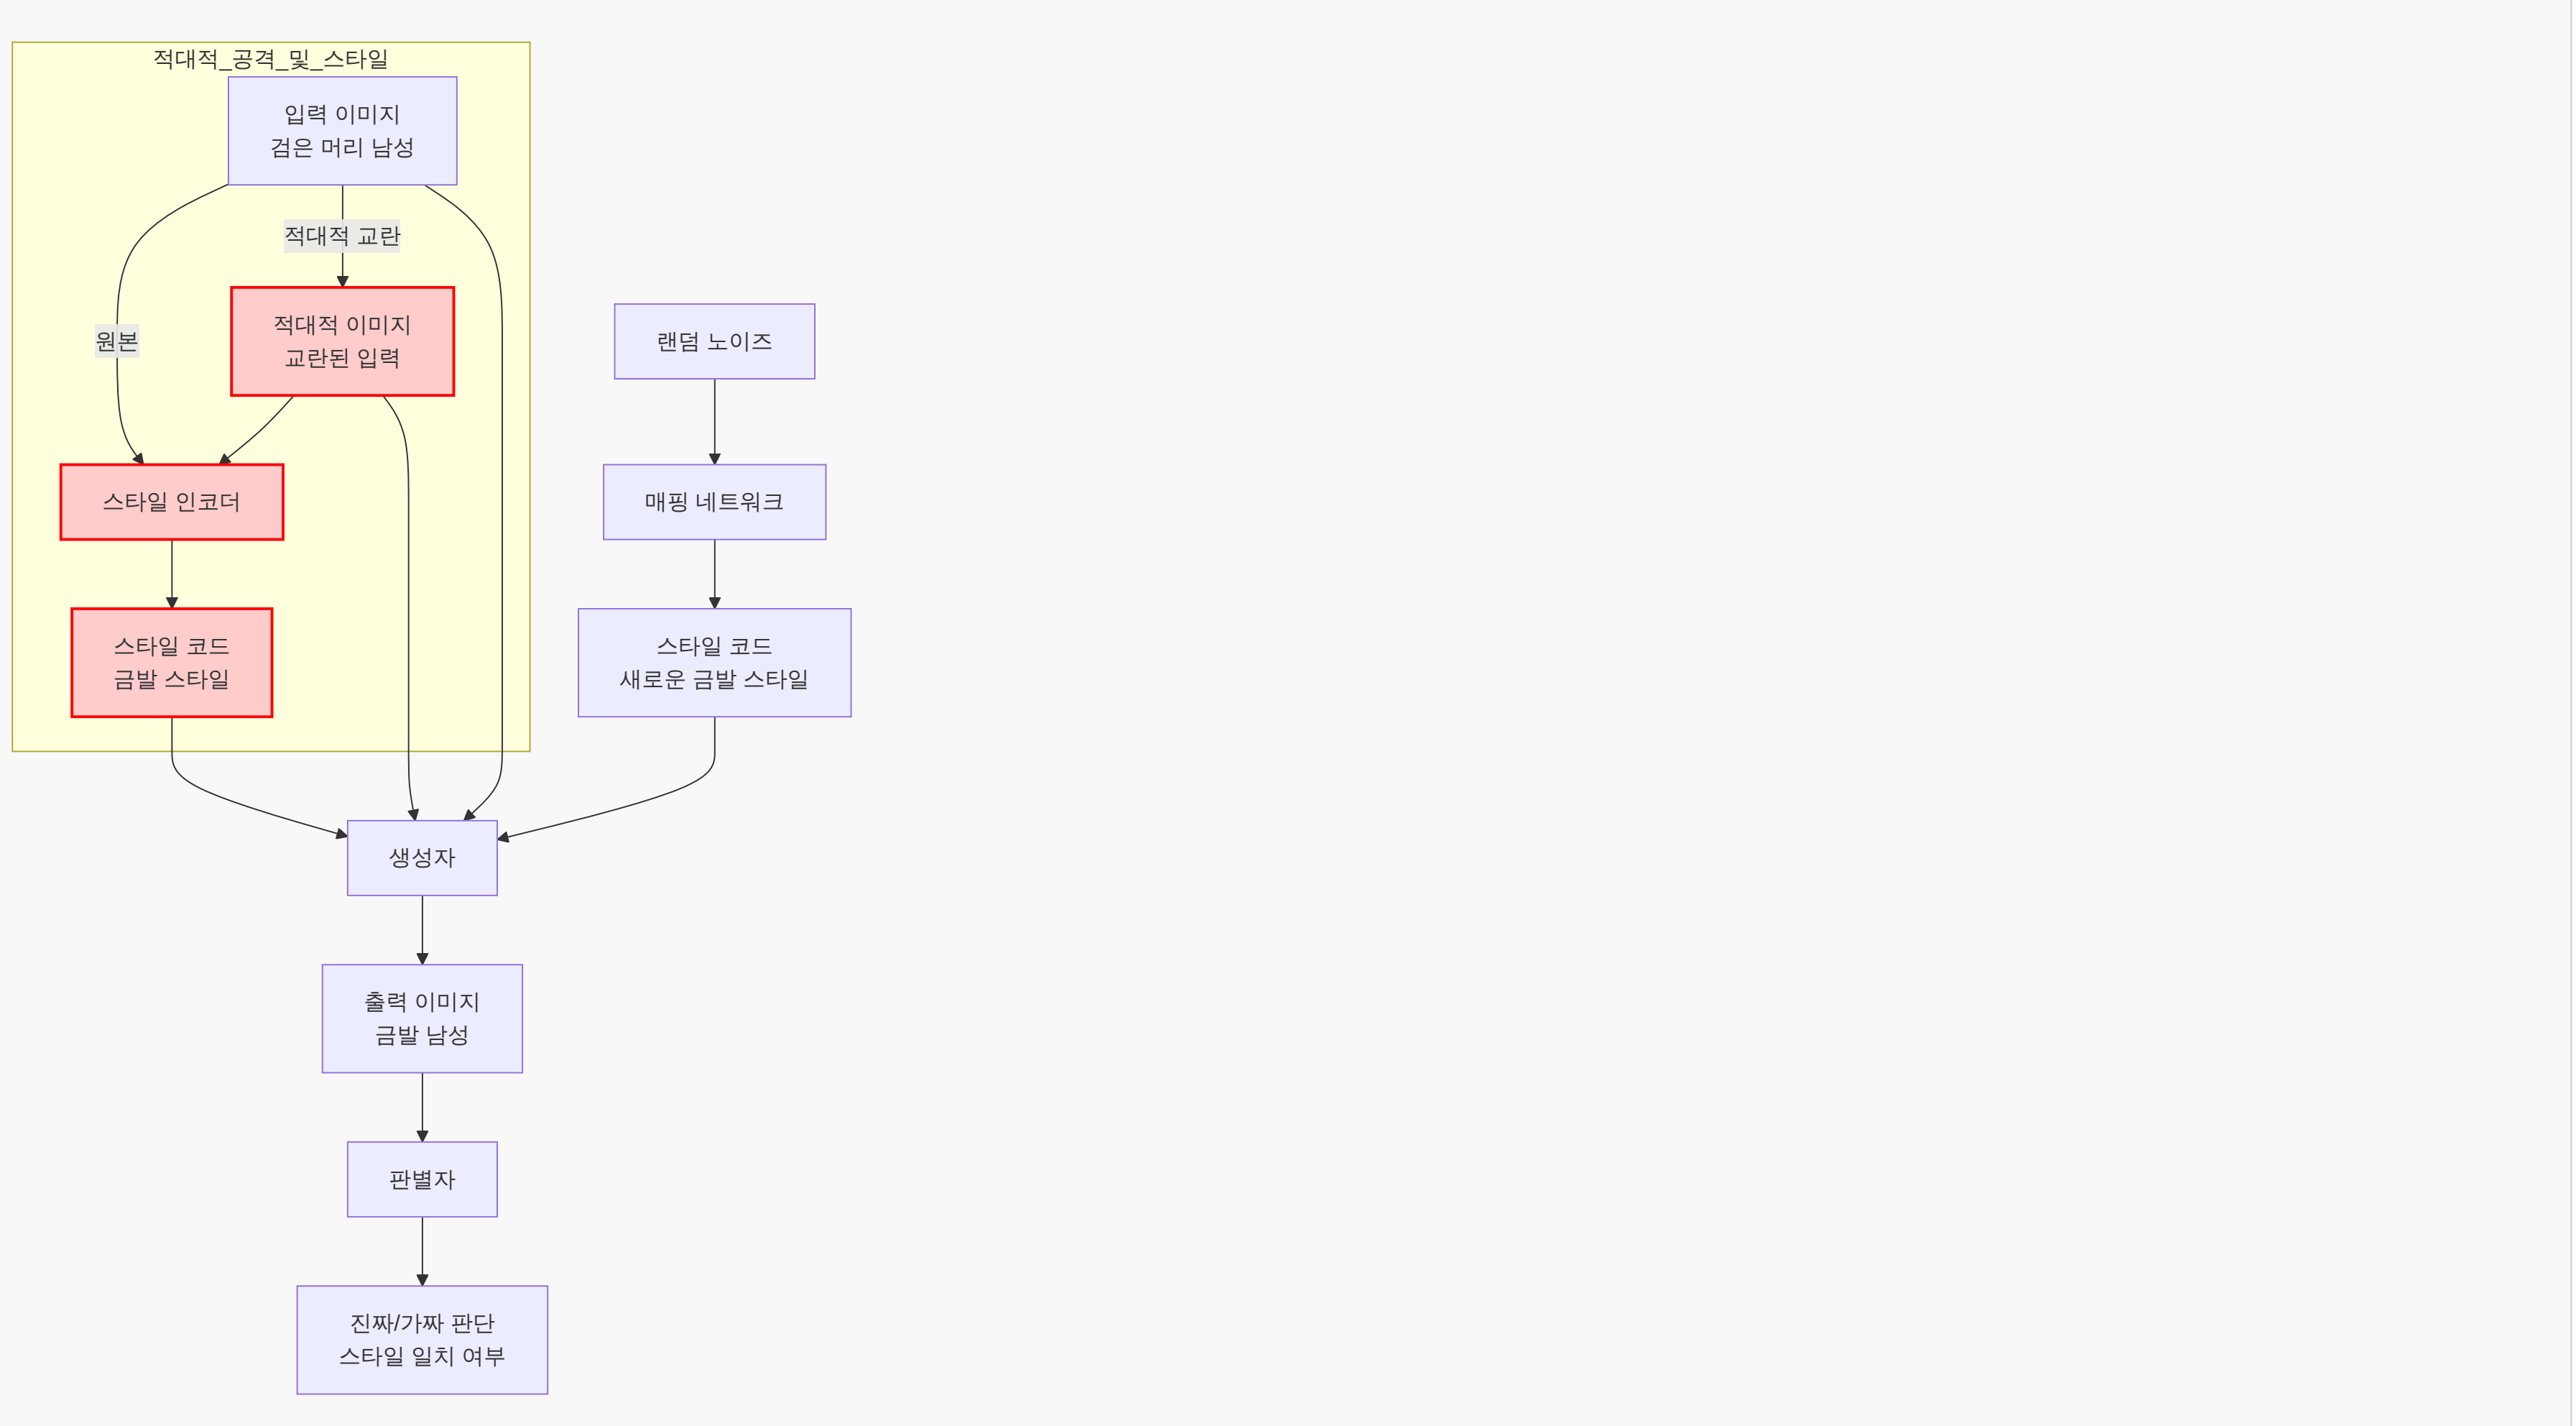
적대적_공격_및_스타일
입력 이미지
검은 머리 남성
적대적 교란
원본
적대적 이미지
교란된 입력
랜덤 노이즈
스타일 인코더
매핑 네트워크
스타일 코드
금발 스타일
스타일 코드
새로운 금발 스타일
생성자
출력 이미지
금발 남성
판별자
진짜/가짜 판단
스타일 일치 여부

- PGD의 장점

  -강력함: 단일 단계 공격보다 효과적인 교란 생성

  -조정 가능: epsilon, alpha로 교란 강도 제어

  -유연성: LPIPS, MSE 등 다양한 손실 함수 결합 가능

  -안정성: 반복적 최적화로 신뢰할 수 있는 결과 제공

- 딥페이크 대응 모델로 PGD를 선택한 이유

  -FGSM같은 단일단계공격보다 더 정교한 반복적 접근법 사용. 여러 번에 걸쳐서 노이즈를 조금씩 조정하면서 모델이 인식하지 못할 정도로 미세하지만, 최대한 효과적인 방향으로 데이터를 변형

  -PGD는 수학적으로 안정적이고 이론적 기반이 탄탄

4. 필터 구현 및 결과

PGD 적용 Before/After

Before

After

- **Before**: 적대적 노이즈 적용 전
- **After**: 적대적 노이즈 적용 후 결과

이미지에 미세한 조정을 하여 사람 눈으로 차이를 바로 알아보기 어렵다.

StarGANv2 딥페이크 테스트 결과

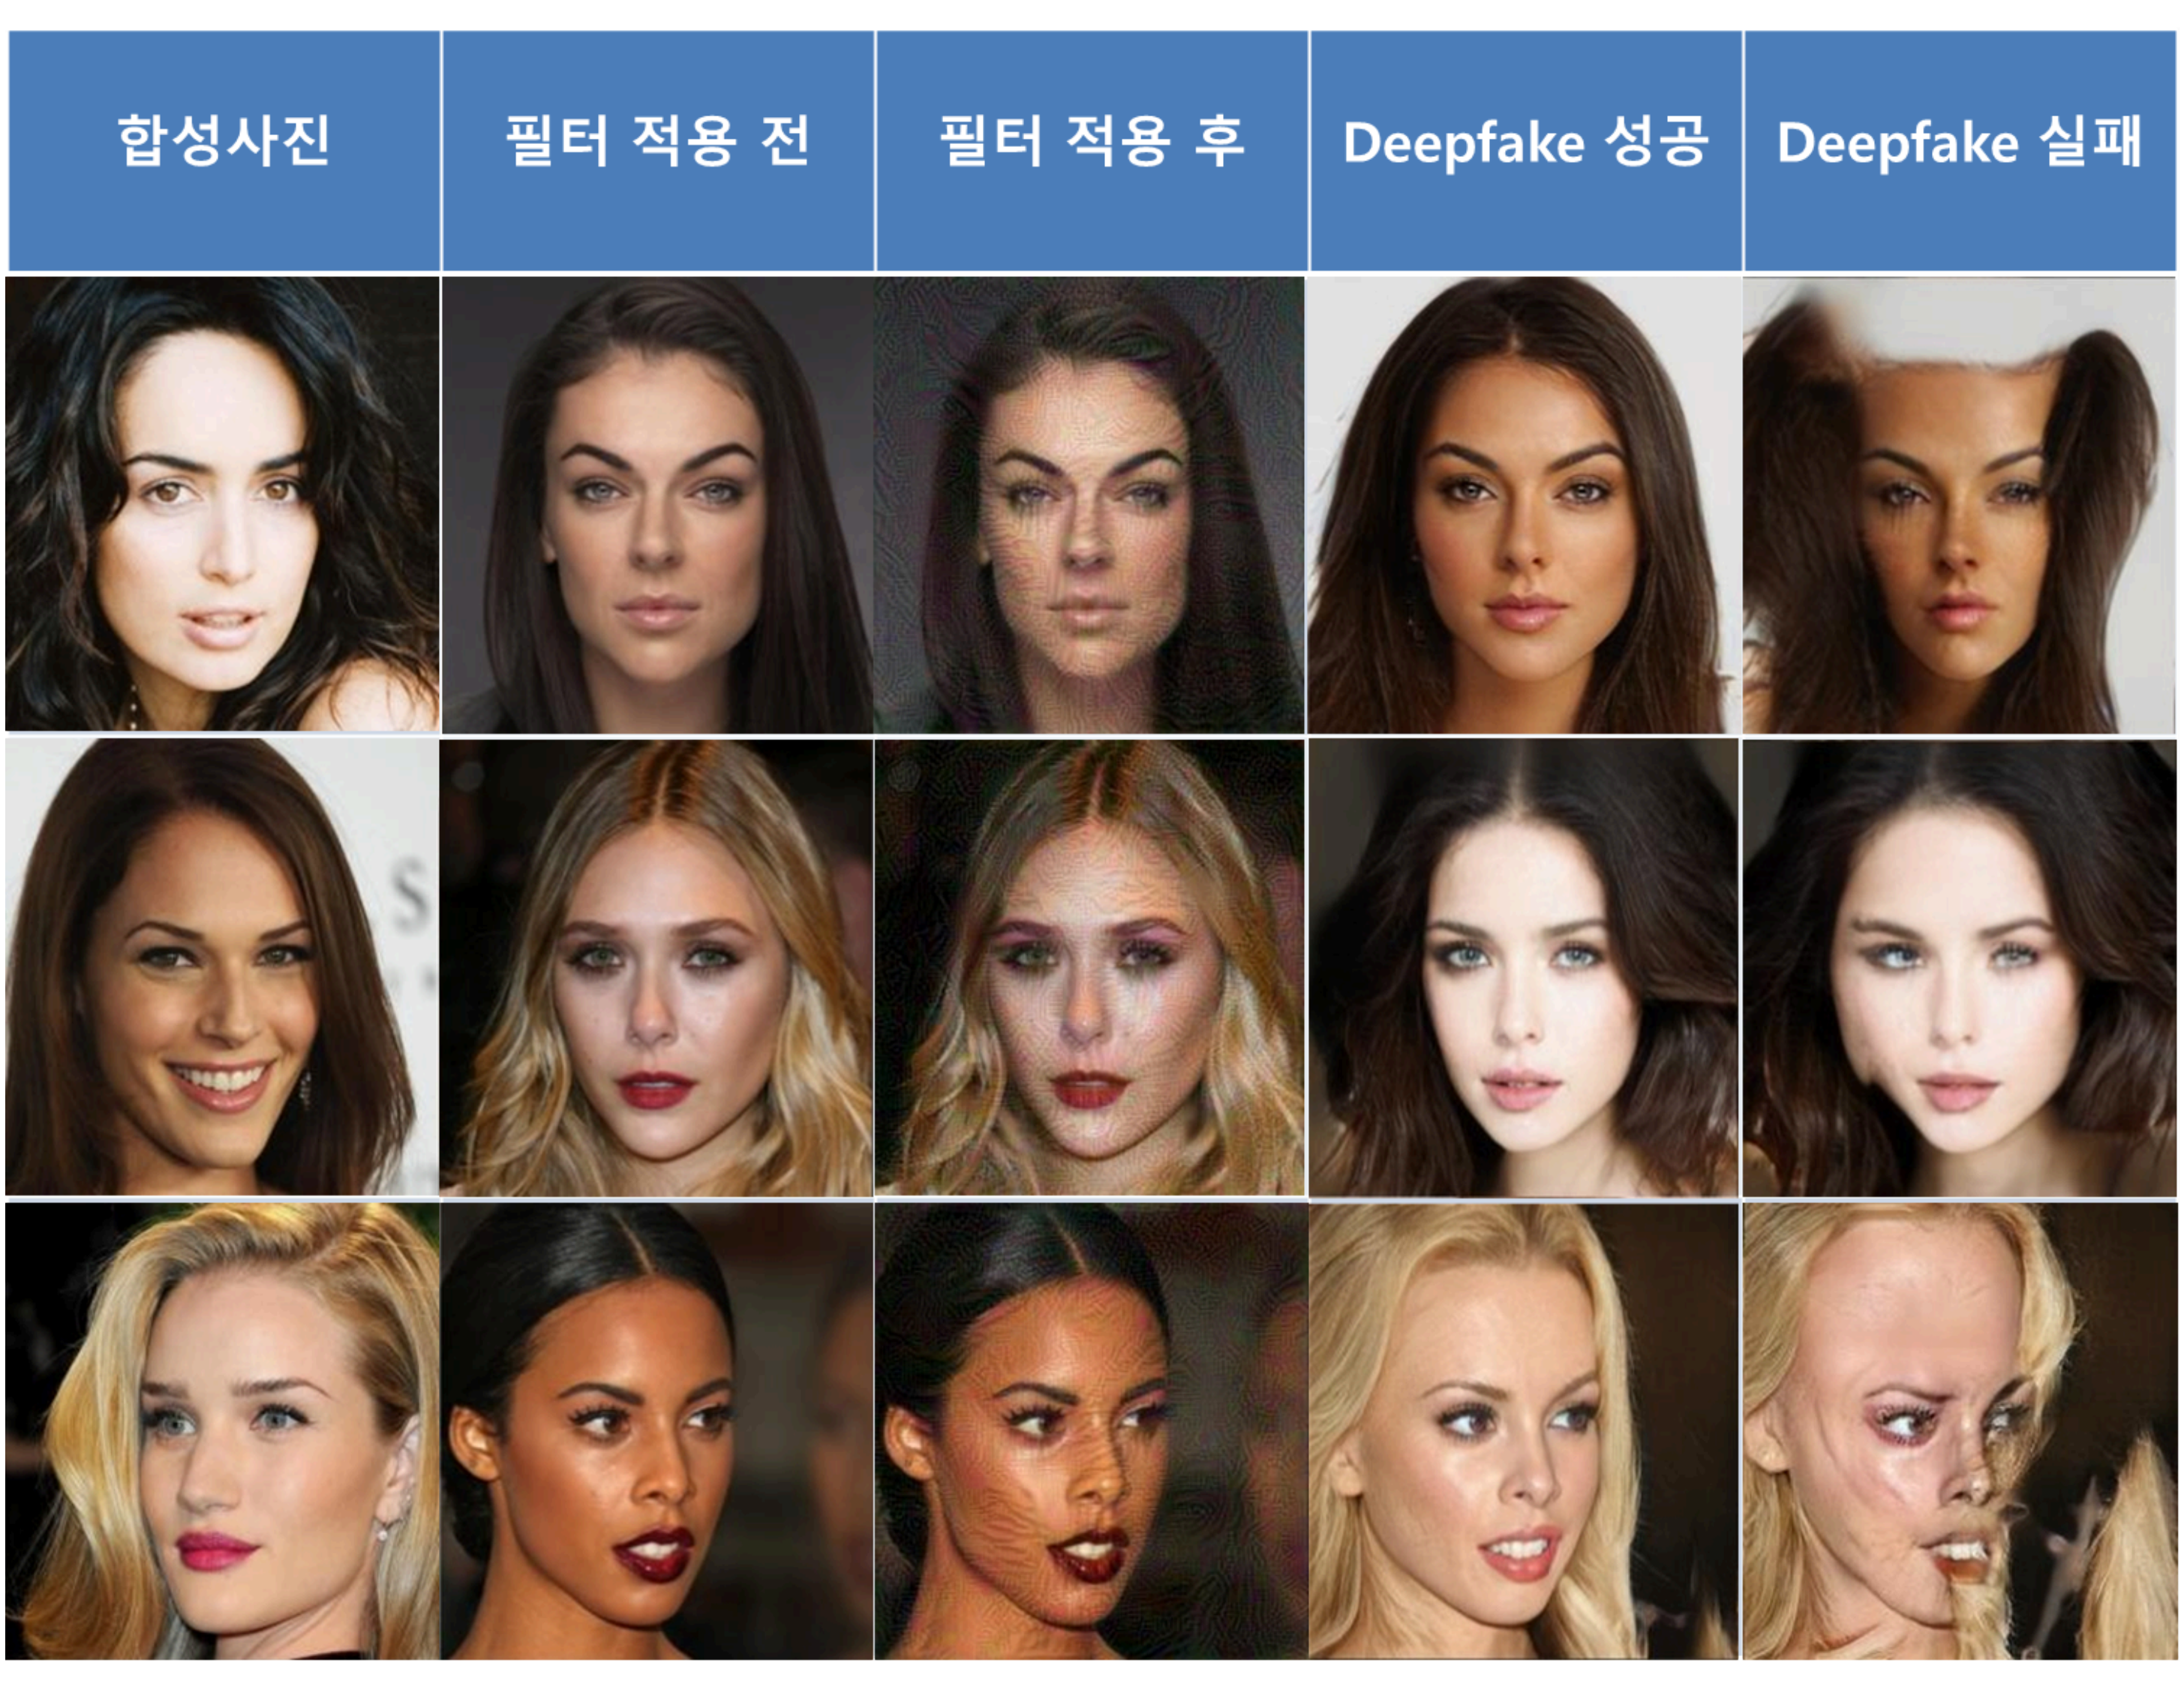
합성사진
필터 적용 전
필터 적용 후
Deepfake 성공
Deepfake 실패

5. 프로젝트 일정 및 개발 흐름

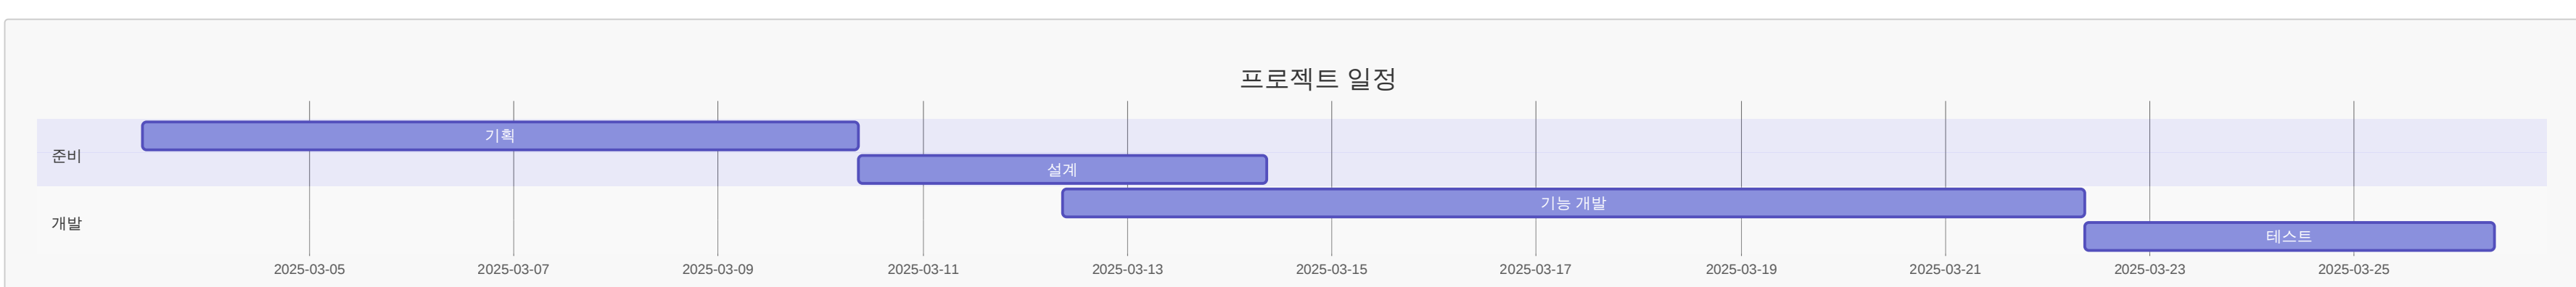

6. 웹 애플리케이션

전체 아키텍처

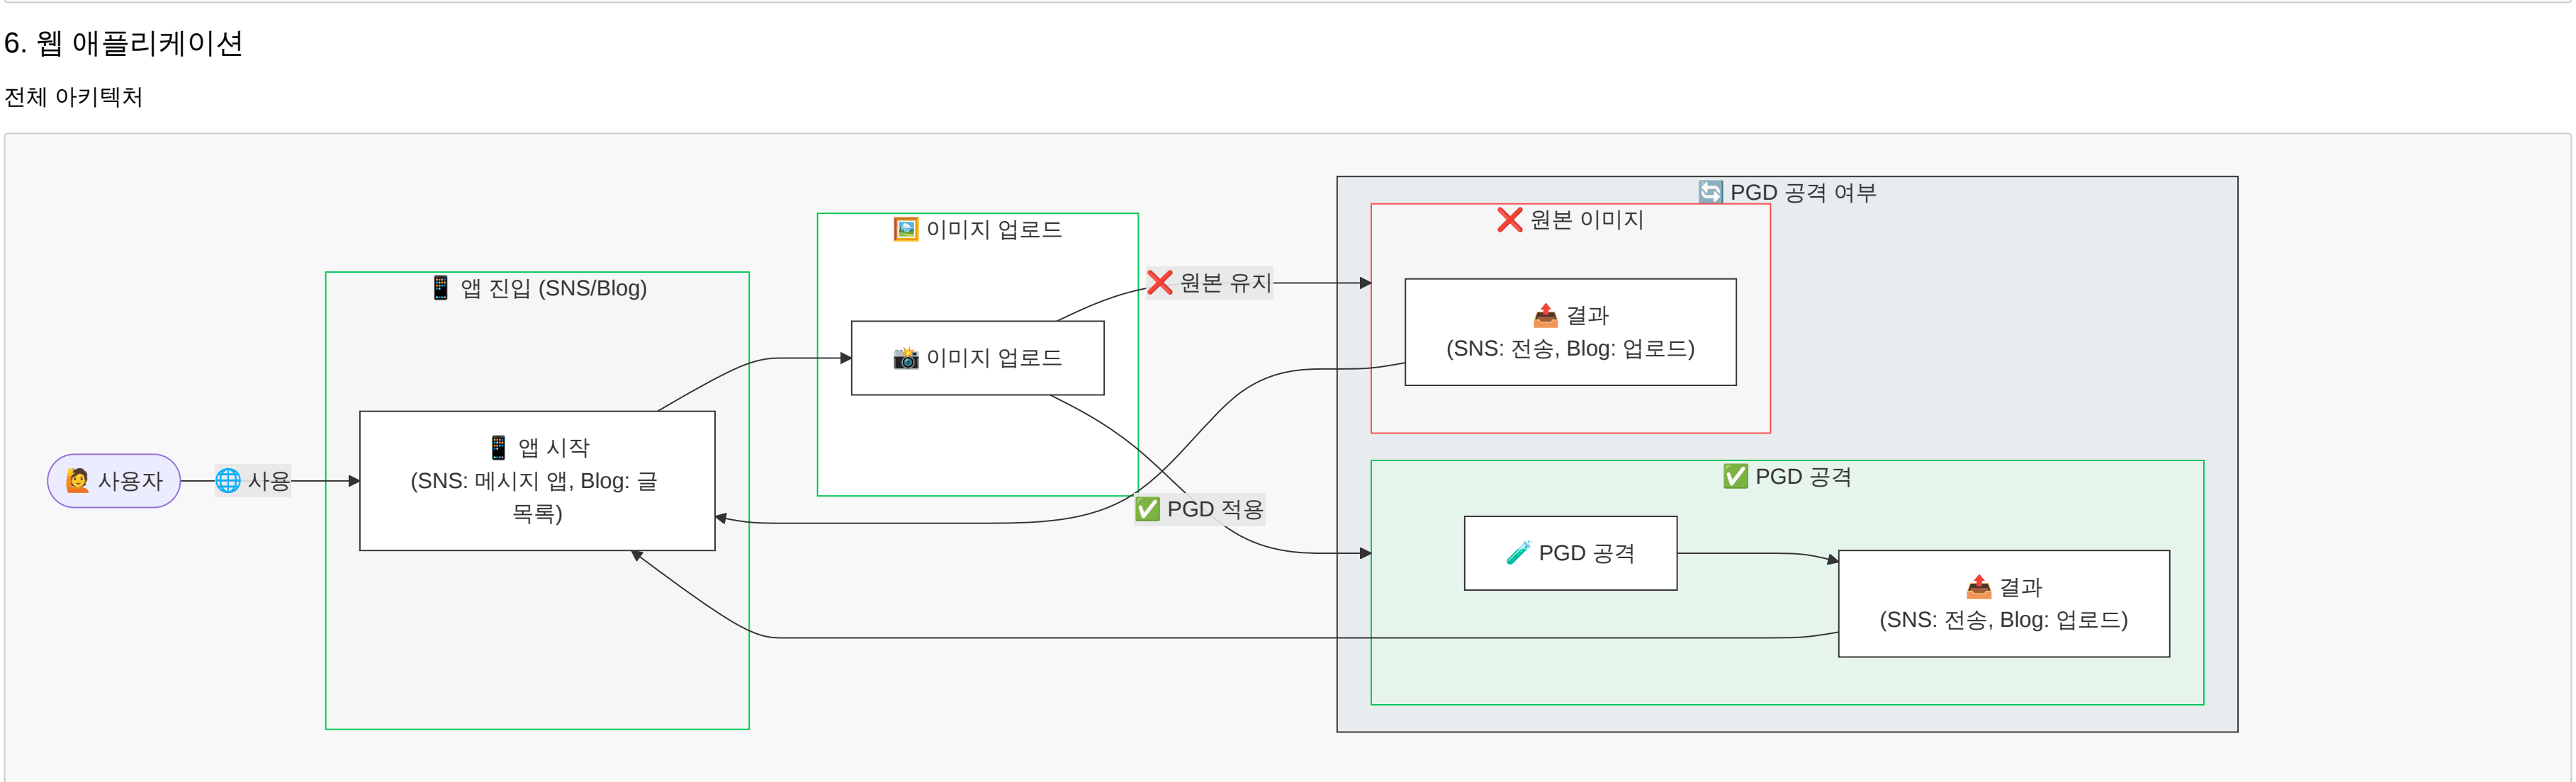
🙋 사용자
🌐 사용
📱 앱 진입 (SNS/Blog)
📱 앱 시작
(SNS: 메시지 앱, Blog: 글 목록)
🖼️ 이미지 업로드
📸 이미지 업로드
❌ 원본 유지
✅ PGD 적용
🔄 PGD 공격 여부
❌ 원본 이미지
📤 결과
(SNS: 전송, Blog: 업로드)
✅ PGD 공격
🧪 PGD 공격
📤 결과
(SNS: 전송, Blog: 업로드)

SNS/블로그 사용자 흐름도

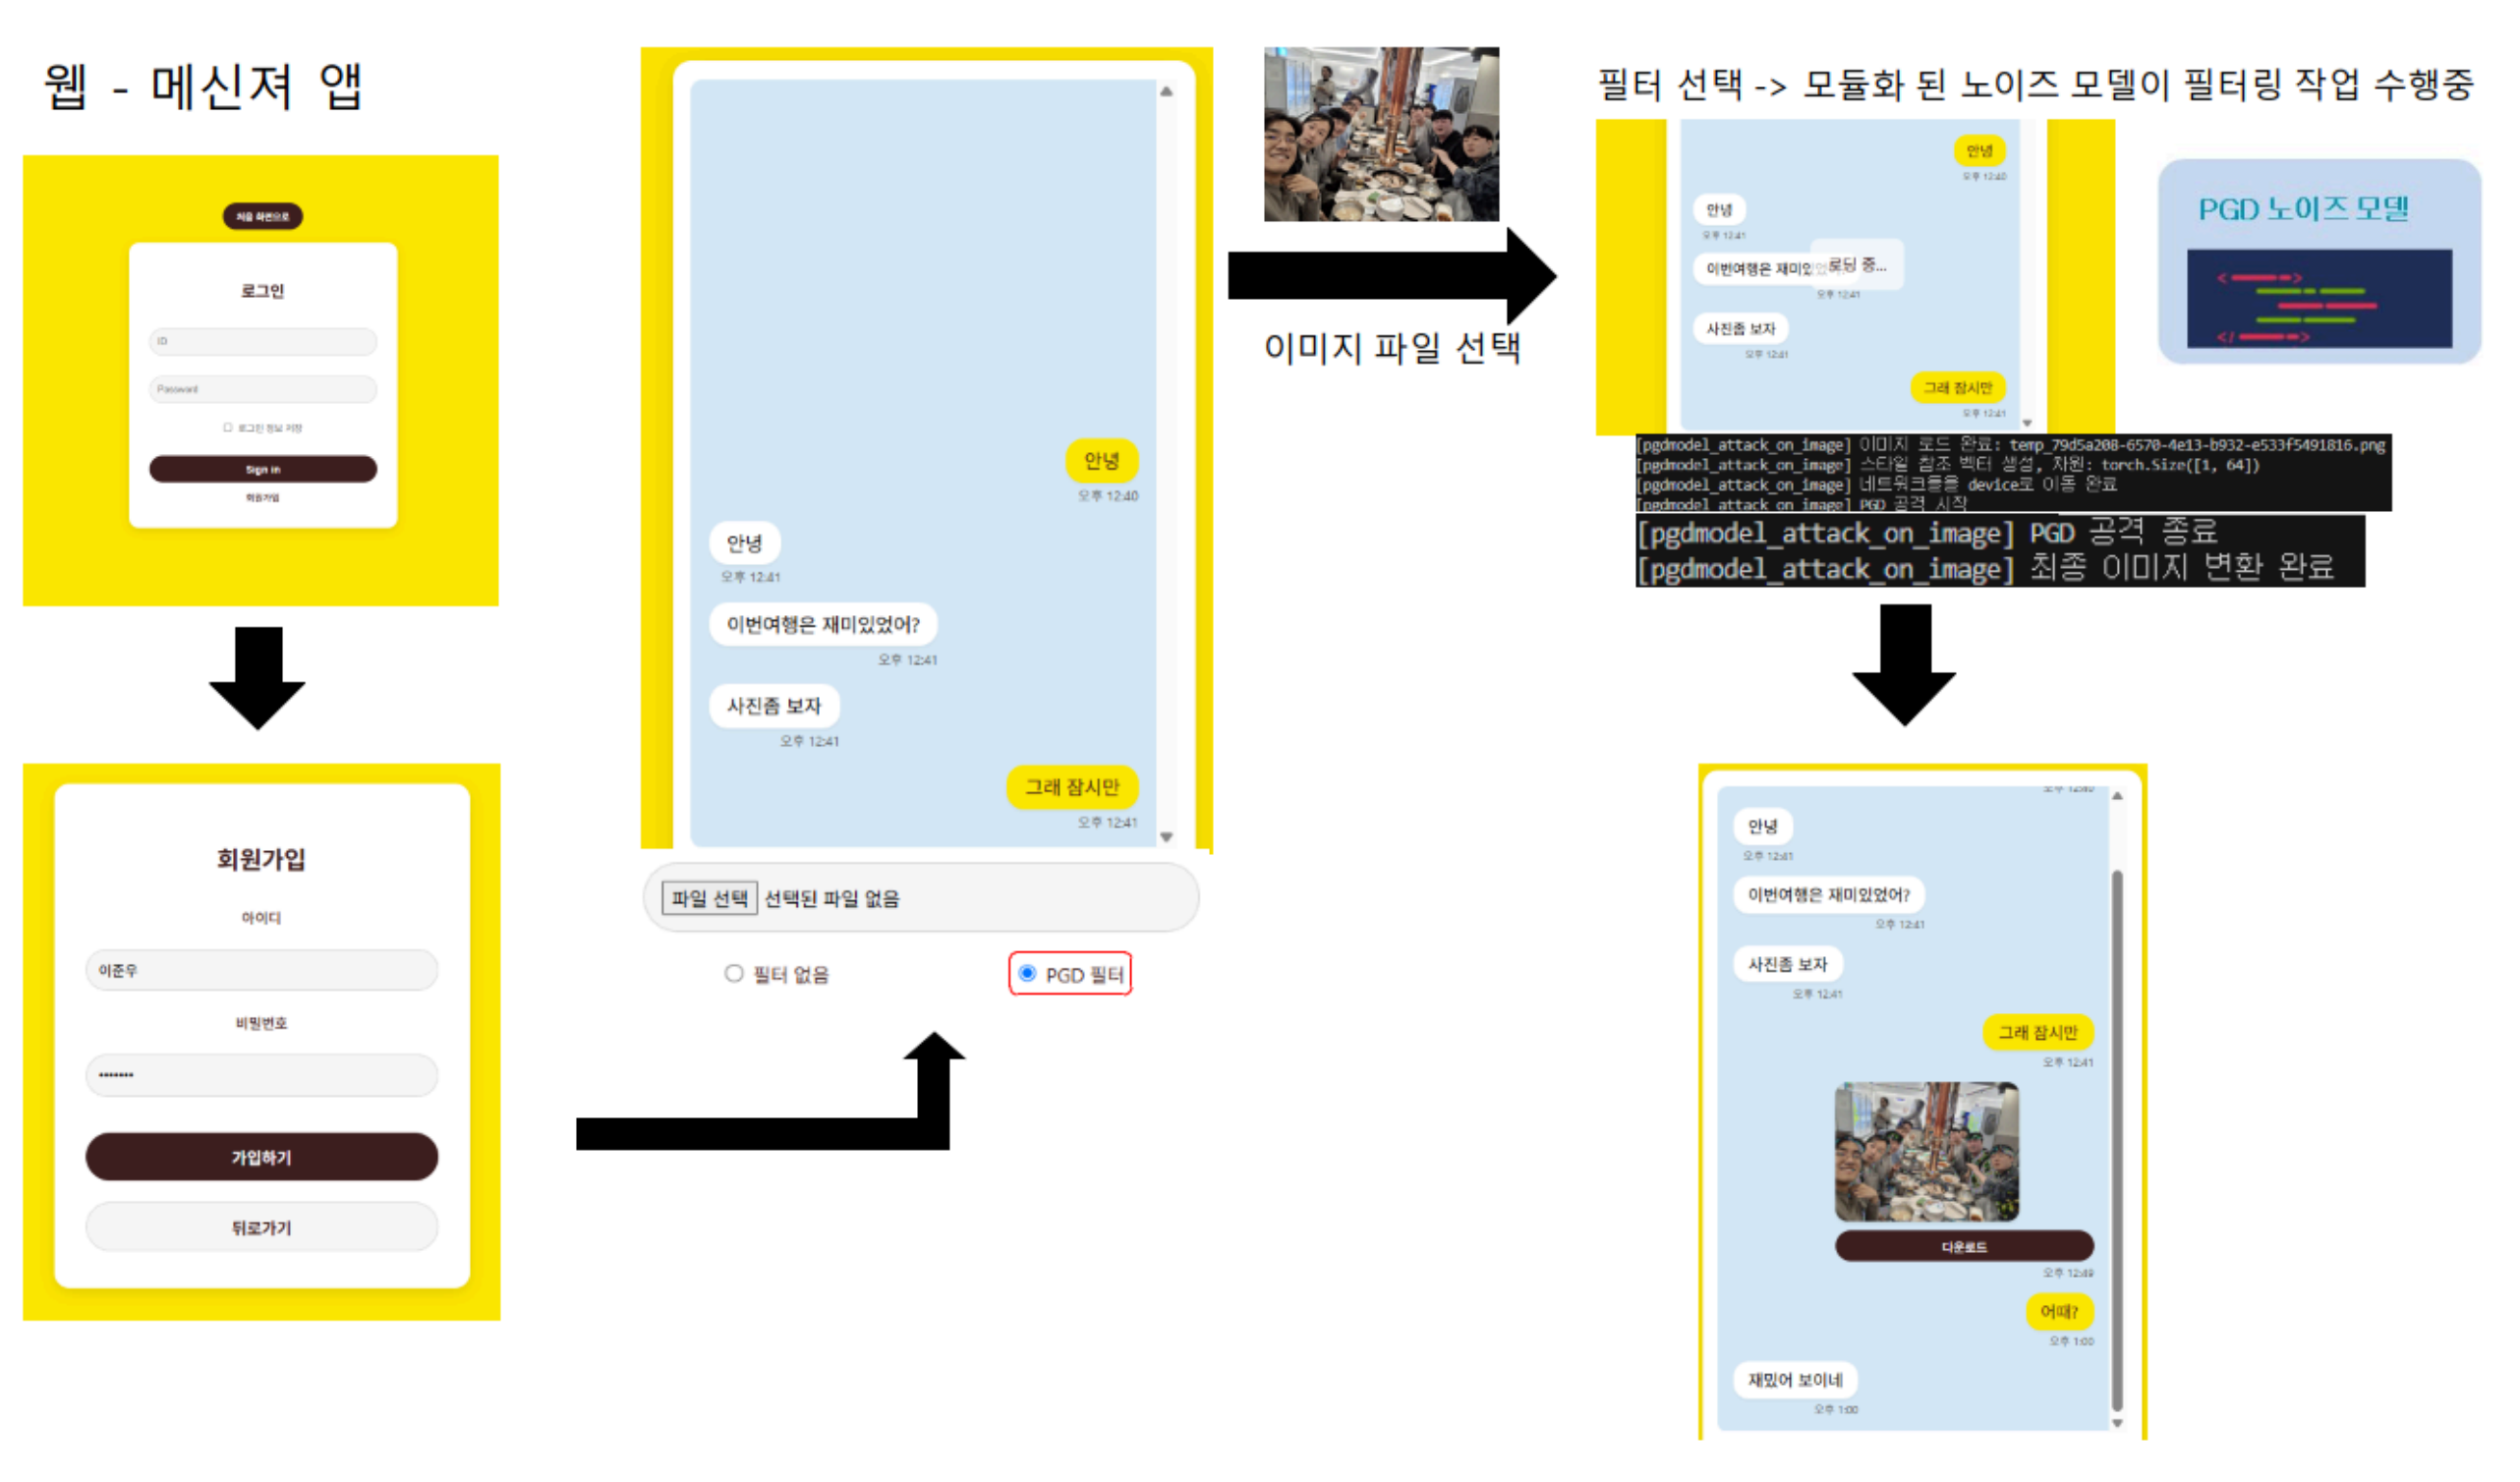
웹 - 메신저 앱
로그인
Sign in
회원가입
가입하기
되돌가기
안녕
이번여행은 재미있었어?
사진좀 보자
그래 잠시만
파일 선택
선택된 파일 없음
○ 필터 없음
● PGD 필터
이미지 파일 선택
필터 선택 -> 모듈화 된 노이즈 모델이 필터링 작업 수행중
로딩 중...
PGD 노이즈 모델
다운로드
어때?
재밌어 보이네

```
[pgdmodel_attack_on_image] 이미지 로드 완료: temp_79d5a208-6570-4e13-b932-e533f5491816.png
[pgdmodel_attack_on_image] 스타일 참조 벡터 생성, 차원: torch.Size([1, 64])
[pgdmodel_attack_on_image] 네트워크들을 device로 이동 완료
[pgdmodel_attack_on_image] PGD 공격 시작
[pgdmodel_attack_on_image] PGD 공격 종료
[pgdmodel_attack_on_image] 최종 이미지 변환 완료
```

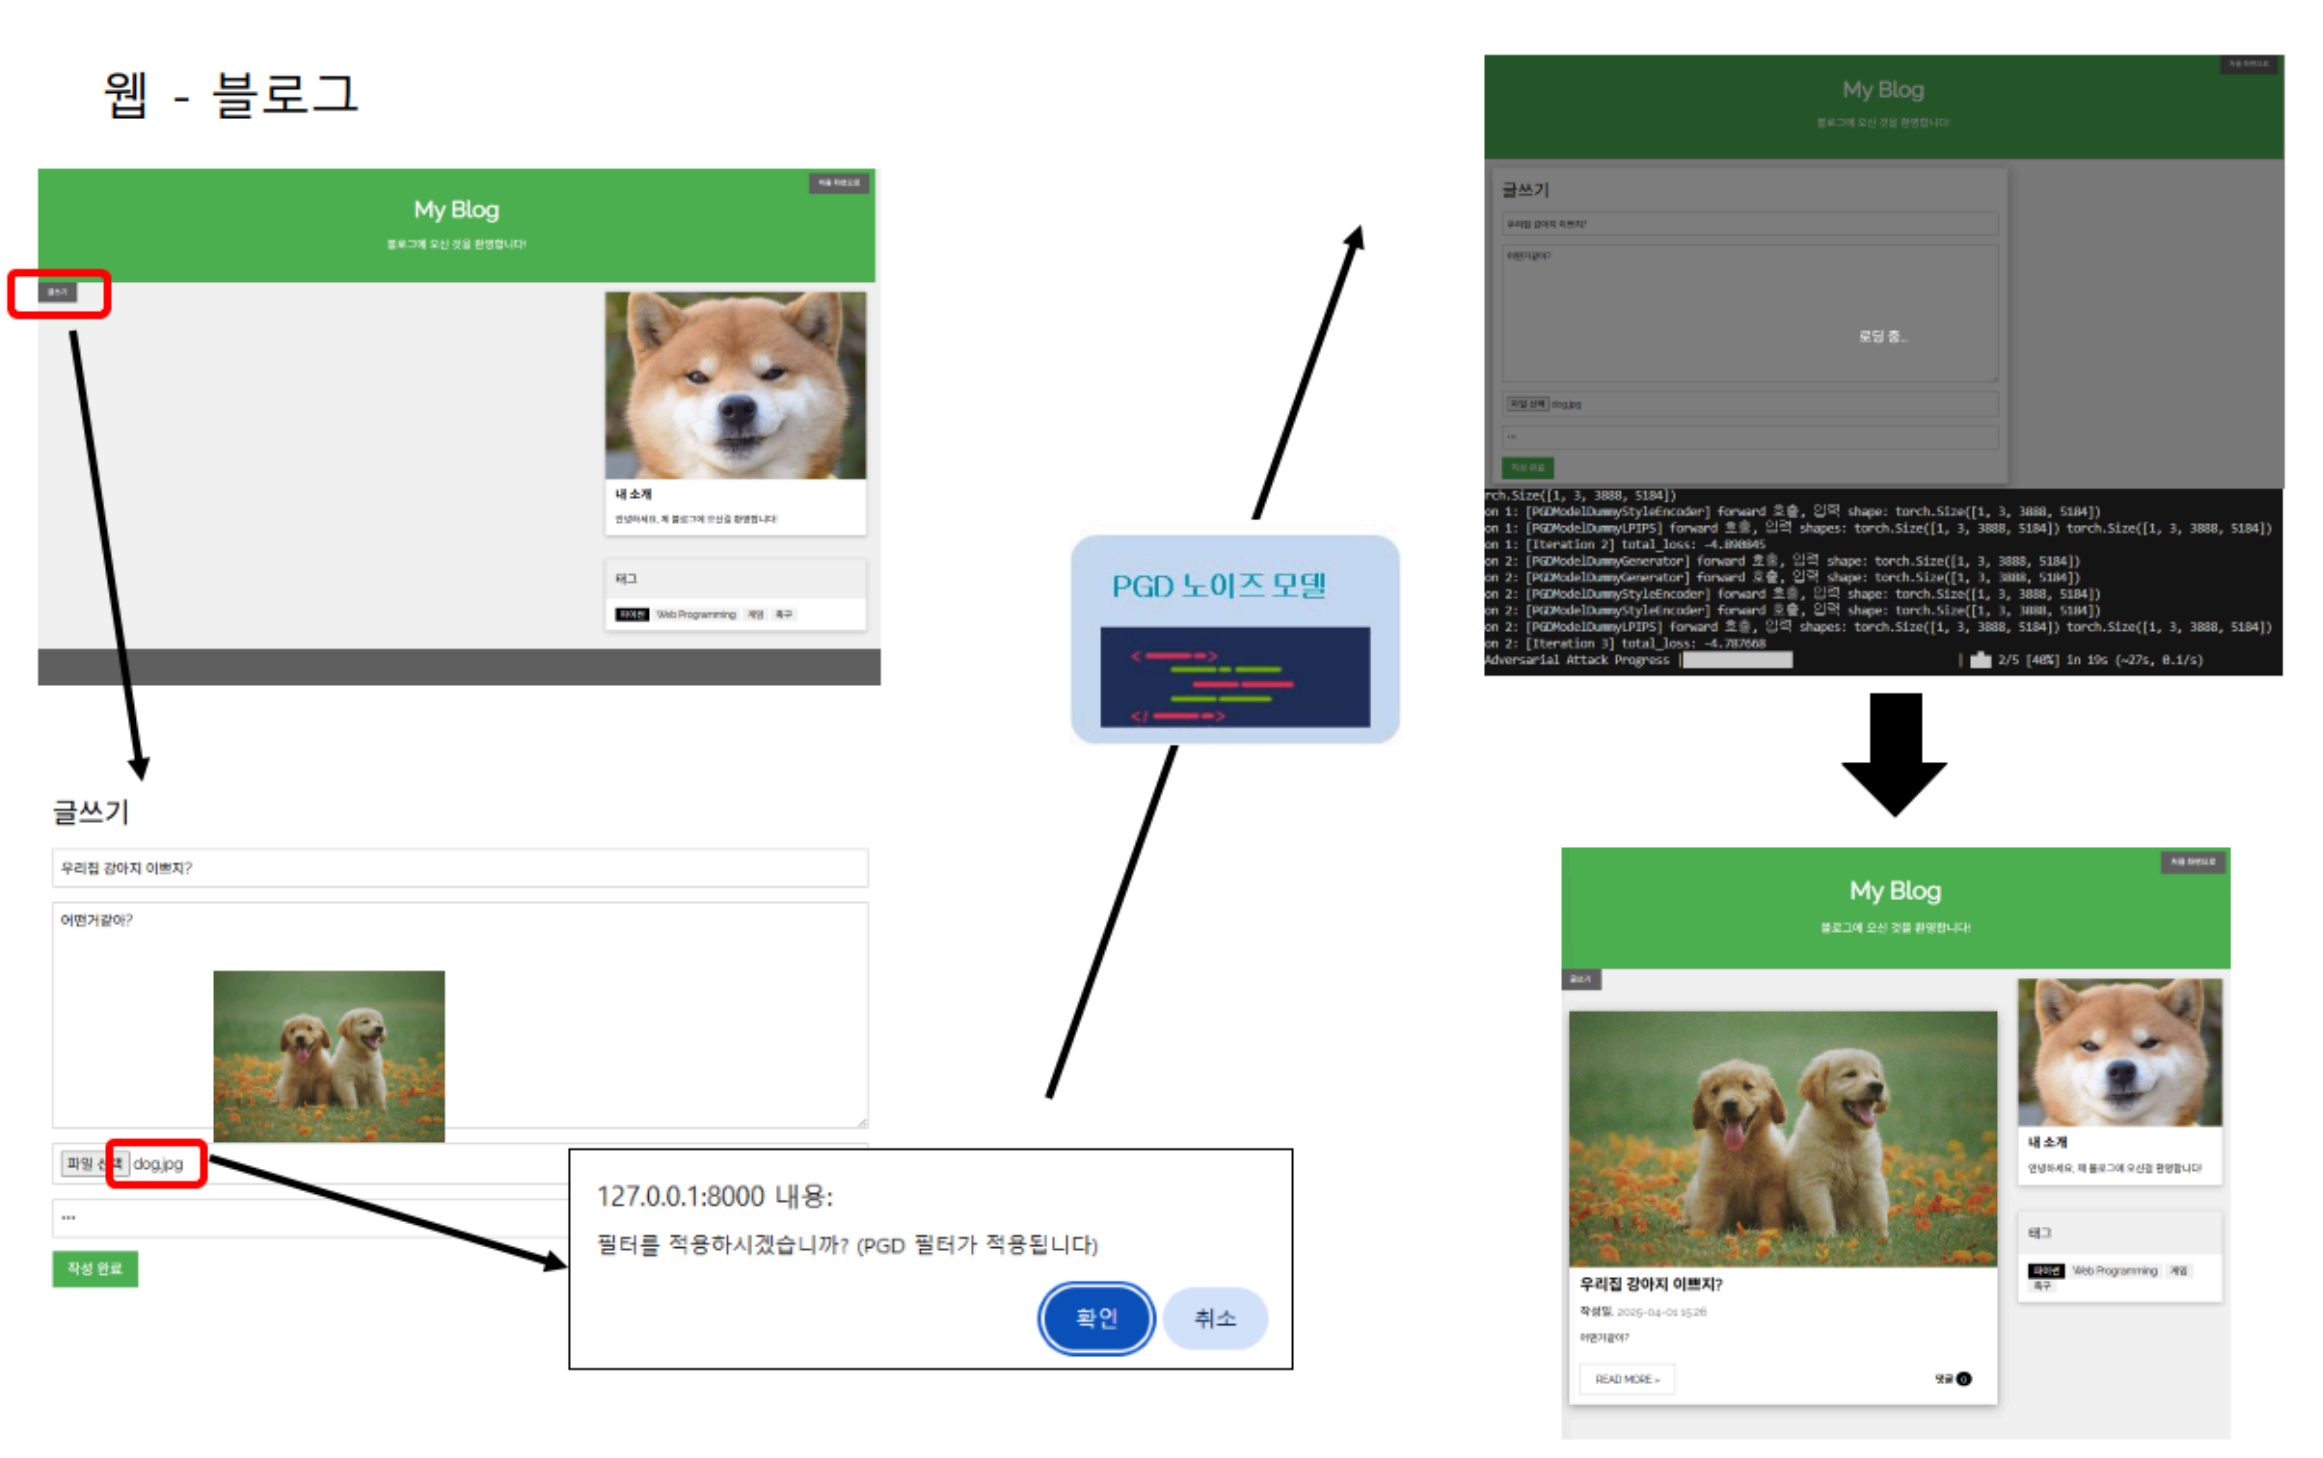
웹 - 블로그
My Blog
글쓰기
우리집 강아지 이쁘지?
어떤거같아?
dog.jpg
작성 완료
PGD 노이즈 모델
로딩 중..
우리집 강아지 이쁘지?
READ MORE »
내 소개
태그
Web Programming

127.0.0.1:8000 내용:

필터를 적용하시겠습니까? (PGD 필터가 적용됩니다)

확인 취소

```
rch.Size([1, 3, 3888, 5184])
on 1: [PGDModelDummyStyleEncoder] forward 호출, 입력 shape: torch.Size([1, 3, 3888, 5184])
on 1: [PGDModelDummyLPIPS] forward 호출, 입력 shapes: torch.Size([1, 3, 3888, 5184]) torch.Size([1, 3, 3888, 5184])
on 1: [Iteration 2] total_loss: -4.898845
on 2: [PGDModelDummyGenerator] forward 호출, 입력 shape: torch.Size([1, 3, 3888, 5184])
on 2: [PGDModelDummyGenerator] forward 호출, 입력 shape: torch.Size([1, 3, 3888, 5184])
on 2: [PGDModelDummyStyleEncoder] forward 호출, 입력 shape: torch.Size([1, 3, 3888, 5184])
on 2: [PGDModelDummyStyleEncoder] forward 호출, 입력 shape: torch.Size([1, 3, 3888, 5184])
on 2: [PGDModelDummyLPIPS] forward 호출, 입력 shapes: torch.Size([1, 3, 3888, 5184]) torch.Size([1, 3, 3888, 5184])
on 2: [Iteration 3] total_loss: -4.787668
Adversarial Attack Progress |          | 2/5 [40%] in 19s (~27s, 0.1/s)
```

7. 웹 백엔드 구성

핵심 기술 스택

> Flask 기반 웹 애플리케이션 + 노이즈 모델 + 프론트엔드 통합 프로젝트
> GitHub Actions를 활용한 CI/CD와 Azure 배포까지 전 과정 포함

🗂️ CI/CD 파이프라인

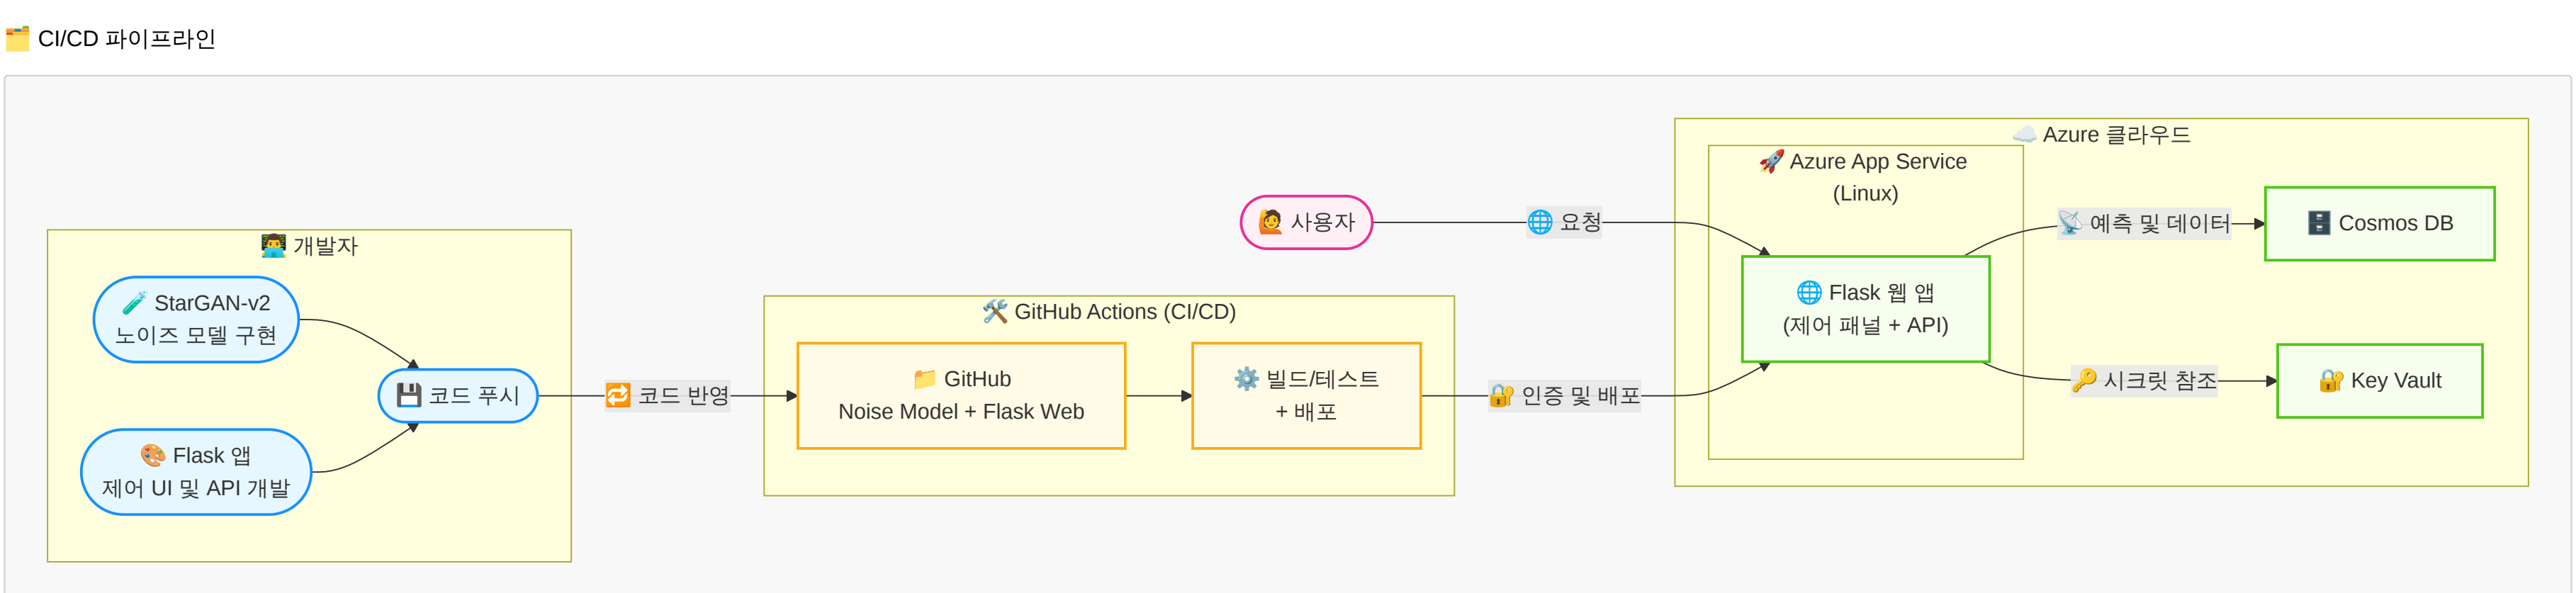
🧑‍💻 개발자
🧪 StarGAN-v2
노이즈 모델 구현
🎨 Flask 앱
제어 UI 및 API 개발
💾 코드 푸시
🔁 코드 반영
🛠️ GitHub Actions (CI/CD)
📁 GitHub
Noise Model + Flask Web
⚙️ 빌드/테스트
+ 배포
🔐 인증 및 배포
🙋 사용자
🌐 요청
☁️ Azure 클라우드
🚀 Azure App Service
(Linux)
🌐 Flask 웹 앱
(제어 패널 + API)
📡 예측 및 데이터
🗄️ Cosmos DB
🔑 시크릿 참조
🔐 Key Vault

데이터베이스 아키텍처

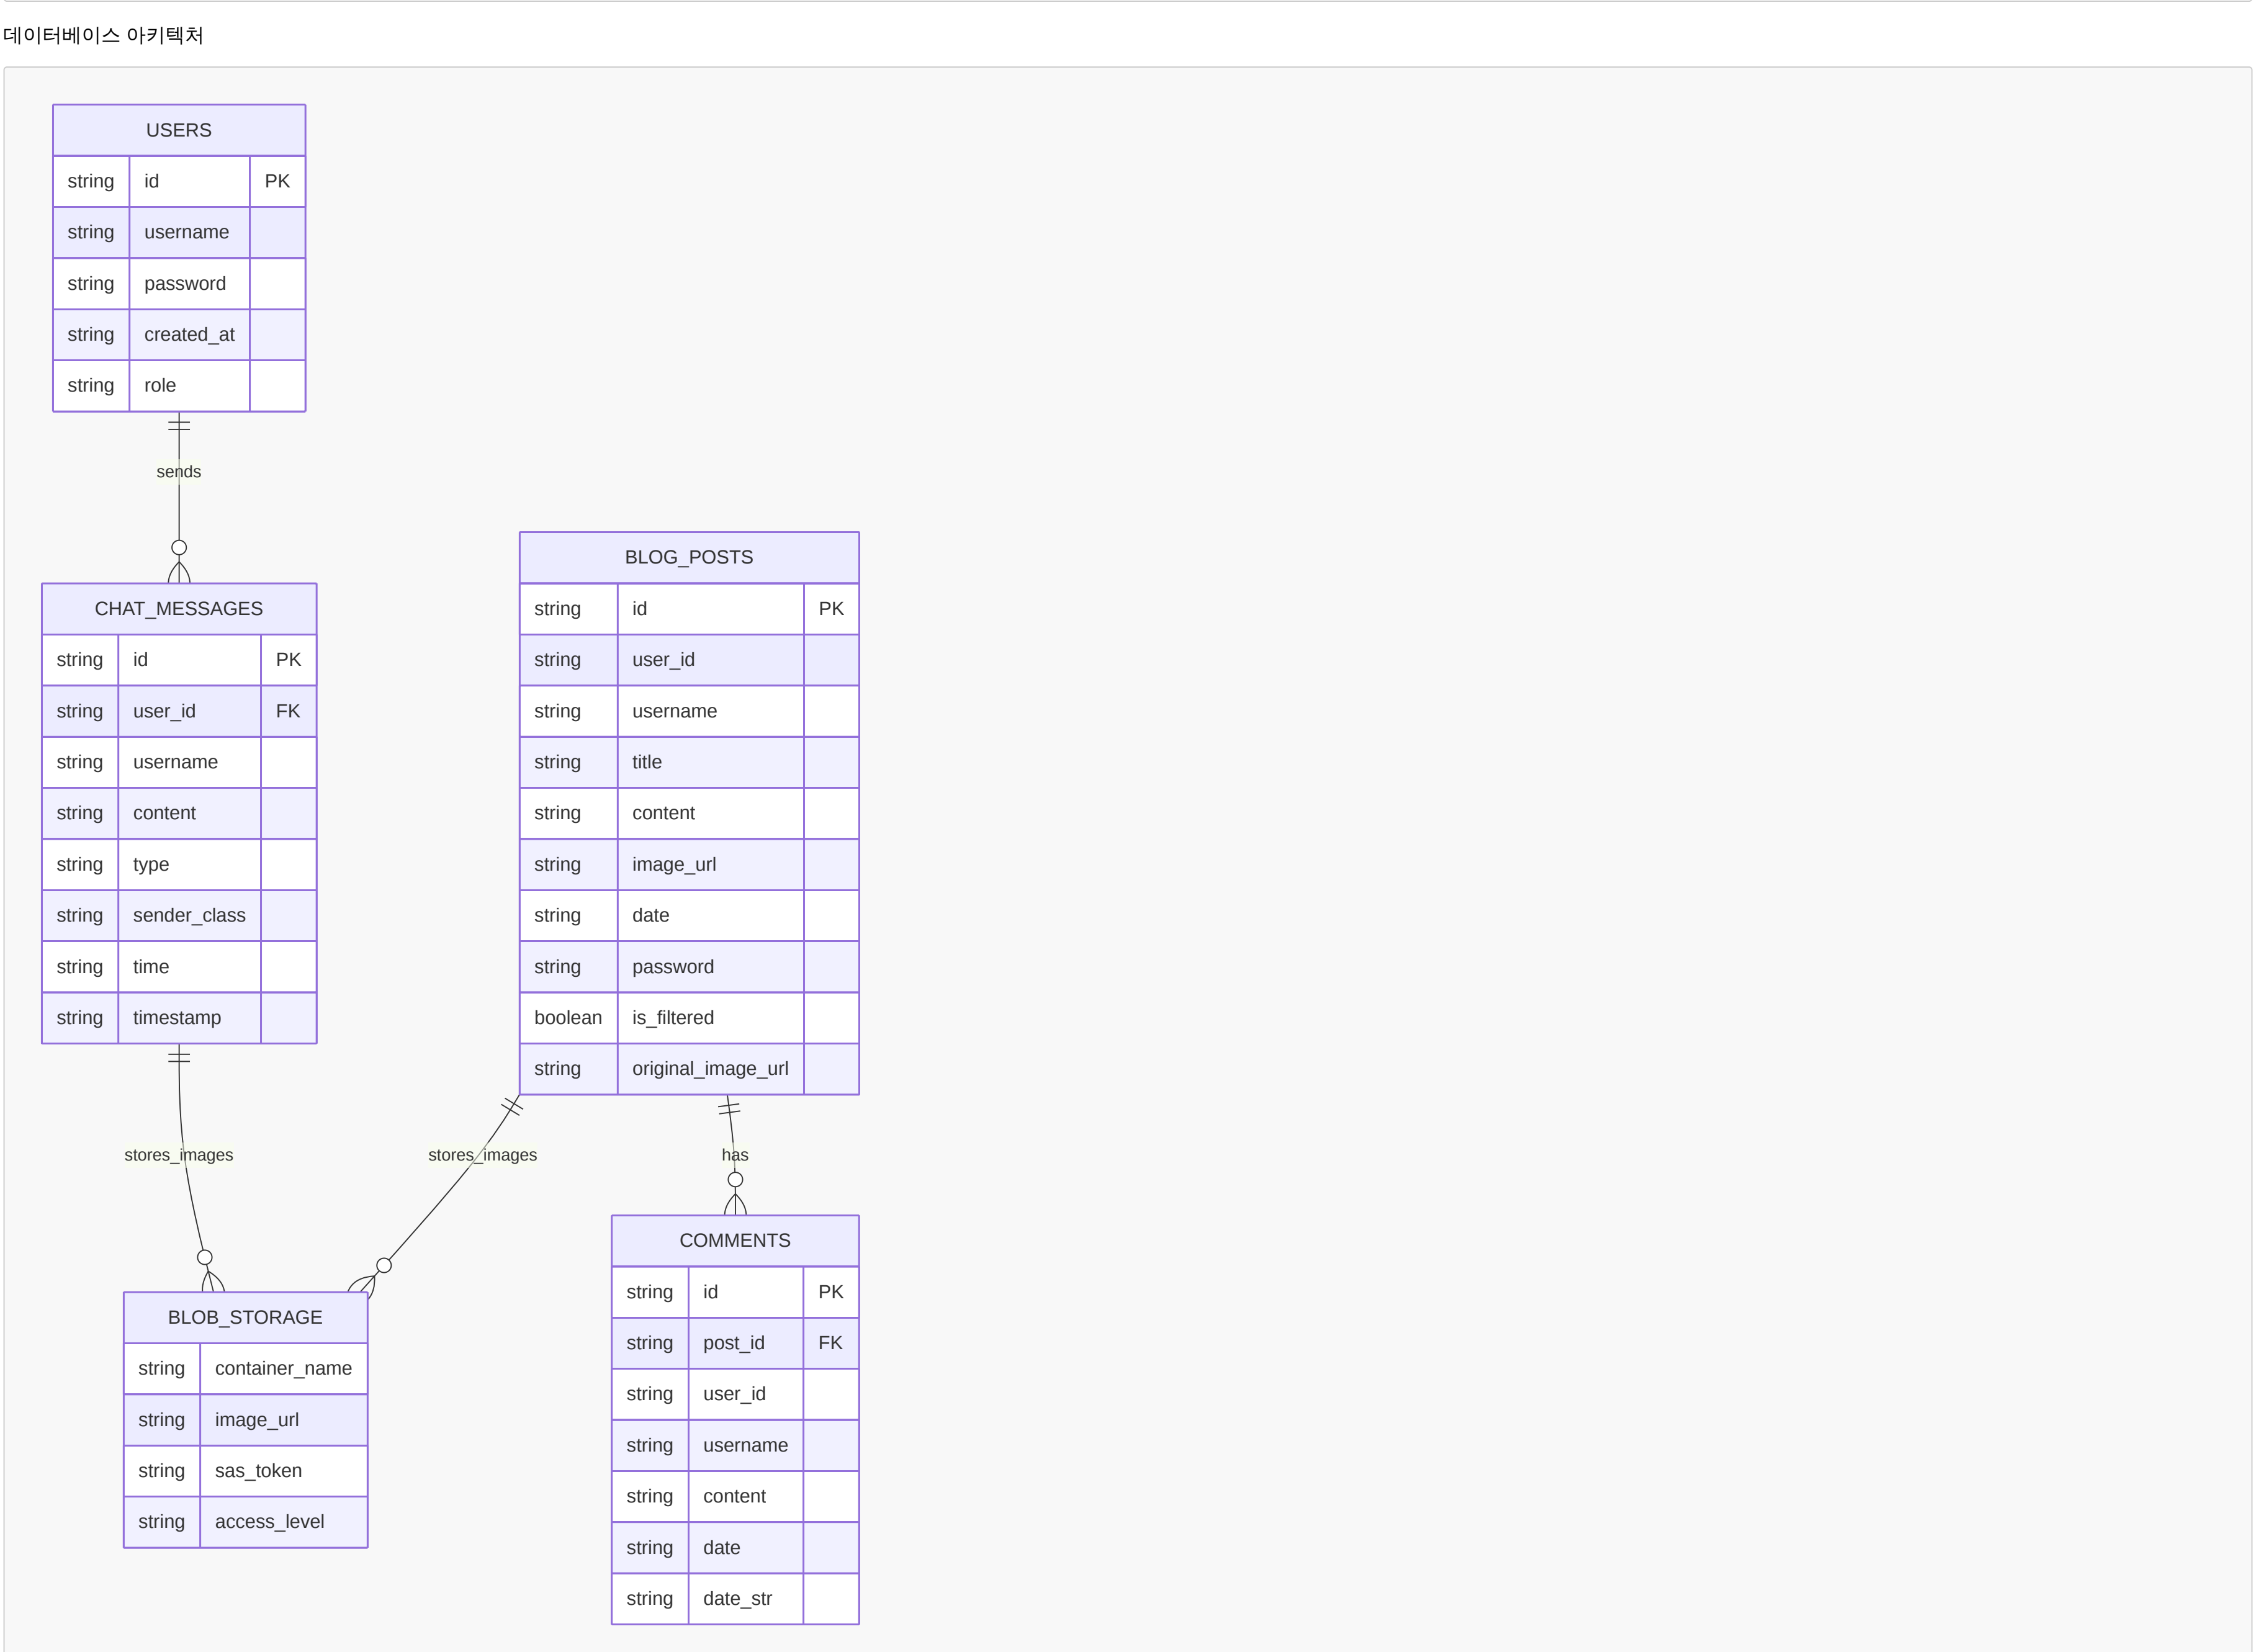
sends
stores_images
stores_images
has

USERS		
string	id	PK
string	username	
string	password	
string	created_at	
string	role	

CHAT_MESSAGES		
string	id	PK
string	user_id	FK
string	username	
string	content	
string	type	
string	sender_class	
string	time	
string	timestamp	

BLOG_POSTS		
string	id	PK
string	user_id	
string	username	
string	title	
string	content	
string	image_url	
string	date	
string	password	
boolean	is_filtered	
string	original_image_url	

BLOB_STORAGE	
string	container_name
string	image_url
string	sas_token
string	access_level

COMMENTS		
string	id	PK
string	post_id	FK
string	user_id	
string	username	
string	content	
string	date	
string	date_str	

시연 자료 링크

AIFAKER

8. 한계점 및 향후 개선 방향

- 공개된 딥페이크 자료가 부족해서 딥페이크의 다양한 모델에 대한 테스트를 진행하지 못함

  모델들의 연구를 더 진행하여 추가 필터 적용 예정

- PGD 기법을 활용해 StarGANv2 딥페이크를 방해하는 필터를 완성하였으나 웹서버에 V2 사전학습 데이터는 이식하지 못함 (현재 웹서버에 적용된 필터는 프로토 타입 모델)

  사전학습 데이터를 웹 서버에 추가하여 더 자연스러운 필터를 구현할 예정